

**“Eksplorasi Data Customer Churn Berdasarkan Segmentasi Pelanggan,
Kualitas Layanan, dan Sensitivitas Harga pada Dataset Telekomunikasi”**



Oleh:

Kelompok 2

Alya Dhamierea Islamay Putri (255150700111019)

Aisyah Berlianti Afriandi (255150700111022)

Salma Ninda Syahputri (255150701111024)

I Dewa Ayu Puspa Dewi (255150700111045)

Dosen:

Bayu Rahayudi, S.T., M.T., M.M.

Program Studi Teknologi Informasi

Fakultas Ilmu Komputer

Universitas Brawijaya

2026

DAFTAR ISI

DAFTAR ISI.....	1
TABEL PENGUMPULAN.....	4
BAB I PENDAHULUAN.....	5
1.1 Latar Belakang.....	5
1.2 Rumusan Masalah.....	5
1.3 Tujuan Penelitian.....	5
1.4 Manfaat Penelitian.....	5
BAB II DASAR TEORI.....	7
2.1 Konsep Dasar Keilmuan.....	7
2.1.1 Data Science.....	7
2.1.2 Machine Learning.....	7
2.2 Konsep Domain Bisnis.....	8
2.2.1 Customer Churn Prediction.....	8
2.2.2 Customer Segmentation.....	8
2.2.3 Kualitas Layanan & Sensitivitas Harga.....	9
2.2.4 Customer Retention.....	11
2.2.5 Customer Churn.....	11
2.2.6 Pricing.....	12
2.2.7 Customer Value.....	13
2.2.8 Customer Lifetime Value.....	13
2.3 Metodologi Data & Analysis.....	13
2.3.1 Data Preprocessing.....	13
2.3.2 Exploratory Data Analysis (EDA).....	14
2.3.2 Data Visualization.....	14
2.4 Teknologi.....	15
2.4.1 Bahasa Pemrograman Python.....	15
2.4.2 Library Pandas.....	15
2.4.3 Library Numpy.....	16
2.4.4 Library Matplotlib.....	16
2.4.5 Library Seaborn.....	17
BAB III METODOLOGI PENELITIAN.....	18
3.1 Jenis Penelitian.....	18
3.2 Dataset.....	18
1. Pilar Analisis Segmentasi Aktivitas & Perilaku Pelanggan (Segmentation).....	19
2. Pilar Analisis Layanan dan Kendala Pelanggan (Service & Pain Points).....	20
3. Pilar Analisis Sensitivitas Harga dan Kondisi Finansial (Financial Sensitivity).....	20
3.3 Tahapan Penelitian.....	21
3.4 Data Preprocessing.....	22

3.5 General EDA.....	25
3.6 Specific EDA.....	26
3.6.1 Segmentasi.....	26
3.6.2 Service Quality.....	30
3.6.2.1 Pendahuluan.....	30
3.6.2.2 Pembentukan Dataset Populasi Churn.....	32
3.6.2.3 Statistik Deskriptif.....	33
3.6.2.4 Analisis Distribusi Variabel.....	33
3.6.2.5 Analisis Hubungan Churn.....	33
3.6.2.7 Analisis Multivariat.....	34
3.6.2.8 Validasi Outlier.....	34
3.6.2.9 Analisis Korelasi.....	35
3.6.3 Analisis Finansial dan Sensitivitas Harga.....	35
3.6.3.1 Analisis Komparatif Sebaran Bill-to-Income Ratio.....	35
3.6.3.2 Analisis Komparatif Nominal Tagihan Bulanan.....	35
3.6.3.3 Analisis Komparatif Pendapatan Bulanan.....	36
3.6.3.4 Gambaran Variabel Financial Risk.....	36
BAB IV HASIL DAN PEMBAHASAN.....	38
4.1 Hasil Data Preprocessing.....	38
4.1.1. Hasil Setelah Preprocessing.....	38
4.1.2 Perubahan Struktur Dataset (Kolom & Baris).....	38
4.1.3 Rekayasa Fitur Baru (Feature Engineering).....	39
a. Fitur Berbasis Durasi dan Finansial.....	39
b. Fitur Indikator Anomali Perilaku.....	39
c. Encoding Variabel Kategorikal.....	39
d. Ekstraksi Fitur Teks (Text Preprocessing).....	40
4.1.4 Karakteristik Dataset Final.....	40
4.2 Hasil General EDA.....	40
4.3 Hasil Analisis Customer Segmentation.....	42
4.3.1 Segmentasi Pelanggan Berdasarkan K-Means Clustering.....	43
4.4 Hasil Analisis Service Quality.....	44
4.4.1 Persiapan Dataset.....	45
4.4.2 Statistik Deskriptif.....	46
4.4.3 Distribusi Variabel pada Populasi Churn.....	48
4.4.4 Analisis Hubungan Dengan Churn.....	52
4.4.5 Analisis Multivariat.....	54
4.4.6 Validasi Outlier.....	56
4.4.7 Analisis Korelasi.....	56
4.4.8 Ringkasan Insight dan Rekomendasi.....	58
4.4.9 Rekomendasi Bisnis.....	58
4.5 Hasil Analisis Financial Sensitivity.....	59

4.5.1 Analisis Komparatif Sensitivitas Harga dan Finansial Bill-to-Income Ratio.....	59
4.5.2 Analisis Komparatif Nominal Harga.....	59
4.5.3 Hubungan Support Tickets dan Bill-to-Income Ratio.....	60
4.5.4 Analisis Korelasi Variabel Numerik terhadap Churn.....	61
4.5.5 Analisis Proporsi Kasus Churn berdasarkan Financial Risk.....	61
4.5.6 Distribusi Bill-to-Income Ratio Berdasarkan Financial Risk.....	62
4.6 Insight Bisnis.....	63
4.6.1 Segmentasi Pelanggan Mengungkap Fenomena Wasted Value.....	63
4.6.2 Frekuensi Keluhan dan Jenis Kontrak Sebagai Sinyal Churn Terukur.....	63
4.6.3 Tekanan Finansial Bersifat Universal Lintas Demografi.....	64
4.6.4 Integrasi Insight: Efek Berlipat Antar Dimensi.....	64
4.7 Rekomendasi Bisnis.....	65
4.7.1 Rekomendasi Berdasarkan Analisis Segmentasi (Notebook A).....	65
4.7.2 Rekomendasi Berdasarkan Analisis Kualitas Layanan (Notebook B).....	66
4.7.3 Rekomendasi Berdasarkan Analisis Finansial (Notebook C).....	67
4.7.4 Matriks Strategi Retensi Terintegrasi.....	67
BAB V PENUTUP.....	69
5.1 Kesimpulan.....	69
5.2 Saran.....	70
5.2.1 Saran untuk Pengembangan Proyek.....	70
5.2.2 Saran untuk Perusahaan Telekomunikasi.....	70
DAFTAR PUSTAKA.....	72
LAMPIRAN.....	74

TABEL PENGUMPULAN

LINK DRIVE	 NOTEBOOK_Telecom_Churn_Rate - Kelompok 2
LINK GITHUB	https://github.com/AIU7AgrataEleigh/Telecom-Churn-Rate_Kelompok-2
LINK CANVA	https://canva.link/zn8b5xji967qesi

BAB I

PENDAHULUAN

1.1 Latar Belakang

Churn pelanggan merupakan tantangan penting dalam industri telekomunikasi karena tingginya persaingan antaroperator dan kemudahan pelanggan untuk berpindah layanan (*operator switching*) (Latief et al., 2021). Dari sisi perilaku pelanggan, segmentasi berdasarkan pola penggunaan layanan diperlukan untuk mengenali kelompok pelanggan yang rentan churn dan menyusun strategi retensi yang lebih tepat sasaran. Dari sisi kualitas layanan, masalah seperti kualitas panggilan yang buruk, jaringan tidak stabil, dan gangguan konektivitas internet diketahui menjadi pendorong utama churn (Ribeiro dkk., 2023), sementara kualitas layanan juga berpengaruh terhadap loyalitas melalui kepuasan pelanggan (Yum & Yoo, 2023). Di sisi lain, kondisi finansial pelanggan turut memengaruhi keputusan churn, terutama ketika beban tagihan meningkat di tengah tekanan ekonomi dan sensitivitas harga konsumen (Pakistan Bureau of Statistics, 2026; Khan dkk., 2019). Oleh karena itu, analisis churn pada proyek ini dilakukan melalui tiga perspektif utama, yaitu **segmentasi pelanggan**, **kualitas layanan**, dan **sensitivitas harga**, agar diperoleh gambaran yang lebih komprehensif mengenai faktor-faktor yang memengaruhi churn pelanggan telekomunikasi.

1.2 Rumusan Masalah

1. Bagaimana pola penggunaan layanan pelanggan dapat digunakan untuk mengidentifikasi segmen pelanggan yang rentan mengalami churn?
2. Bagaimana kualitas layanan dan pain points pelanggan berkontribusi terhadap keputusan churn?
3. Bagaimana karakteristik pelanggan yang melakukan churn ditinjau dari aspek harga dan kondisi finansial?

1.3 Tujuan Penelitian

1. Mengidentifikasi segmen pelanggan berdasarkan pola penggunaan layanan dan menganalisis kecenderungan churn pada tiap segmen.
2. Menganalisis hubungan kualitas layanan dan pain points pelanggan terhadap churn.
3. Menganalisis karakteristik pelanggan berdasarkan aspek harga dan kondisi finansial yang melakukan churn

1.4 Manfaat Penelitian

1. Bagi Perusahaan (Manfaat Praktis)
Membantu pihak manajemen telekomunikasi dan tim CRM dalam memetakan karakteristik serta perilaku penggunaan layanan pelanggan secara akurat, sehingga perusahaan dapat merancang strategi retensi yang lebih efektif dan personal untuk mencegah *customer churn*.
2. Bagi Kualitas Layanan & Operasional

Memberikan rekomendasi konkret mengenai aspek operasional apa saja yang menjadi kendala utama pelanggan (*pain points*) serta bagaimana peningkatan kualitas layanan dapat memitigasi keluhan pelanggan sebelum mereka memutuskan untuk *churn*.

3. Bagi Pengambilan Kebijakan Finansial

Menjadi landasan strategis bagi perusahaan dalam menyusun kebijakan harga (*pricing*) dan promosi yang adaptif, dengan mempertimbangkan tingkat stabilitas finansial serta sensitivitas harga dari masing-masing segmen pelanggan.

BAB II

DASAR TEORI

2.1 Konsep Dasar Keilmuan

2.1.1 Data Science

Sains data adalah kumpulan teknik interdisipliner yang digunakan untuk mengekstraksi nilai atau wawasan bermakna dari data (Kotu dan Deshpande, 2019). Bidang ini menggabungkan aplikasi bisnis dari pembelajaran mesin (*machine learning*), statistika, matematika, dan visualisasi untuk menemukan pola dan hubungan tersembunyi guna mendukung pengambilan keputusan yang krusial (Kotu dan Deshpande, 2019). Dalam perspektif praktis, sains data dipandang sebagai sebuah proses berkelanjutan, bukan sekadar peristiwa tunggal, di mana data digunakan sebagai instrumen untuk memahami fenomena dunia nyata melalui validasi hipotesis dan model (Ratnawati, 2024). Secara sistematis, alur kerja sains data umumnya mengikuti enam tahapan utama, yang dimulai dari penetapan tujuan penelitian (*research goal*), pengumpulan data, persiapan data, eksplorasi data, pemodelan, hingga tahap presentasi dan otomatisasi hasil (Ratnawati, 2020).

2.1.2 Machine Learning

Pembelajaran mesin (*machine learning*) merupakan sub-bidang dari kecerdasan buatan (*artificial intelligence*) yang memberikan kemampuan pada sistem komputer untuk belajar dari pengalaman dalam bentuk data (Kotu dan Deshpande, 2019). Definisi klasik menyebutkan bahwa *machine learning* memungkinkan komputer untuk belajar tanpa harus diprogram secara eksplisit untuk setiap detail instruksinya (Ratnawati, 2020). Berbeda dengan pemrograman tradisional, algoritme ini mengambil data pelatihan (*training data*) untuk secara otomatis membangun model perwakilan yang dapat memetakan masukan (*input*) menjadi keluaran (*output*) yang diinginkan (Kotu dan Deshpande, 2019).

Secara metodologis, *machine learning* dibagi menjadi beberapa kategori utama:

1. Supervised Learning: Teknik yang membangun model dengan mendeskripsikan hubungan antara variabel independen dan variabel target yang sudah memiliki label sebelumnya, seperti pada tugas klasifikasi atau regresi (Provost dan Fawcett, 2013).
2. Unsupervised Learning: Teknik yang bertujuan menemukan pengelompokan alami atau regularitas dalam data tanpa didorong oleh variabel target tertentu, yang umumnya diimplementasikan dalam tugas klasterisasi (Provost dan Fawcett, 2013).

Dalam konteks sains data, pembelajaran mesin menjadi alat krusial untuk melakukan prediksi perilaku masa depan, seperti dalam kasus prediksi *churn* pelanggan atau analisis sensitivitas harga (Kotu dan Deshpande, 2019)

2.2 Konsep Domain Bisnis

2.2.1 Customer Churn Prediction

Customer churn, atau sering disebut sebagai *attrition*, didefinisikan sebagai fenomena di mana pelanggan berhenti berlangganan atau berpindah dari satu penyedia layanan ke penyedia layanan lainnya (Provost dan Fawcett, 2013). Di industri telekomunikasi yang pasarnya sudah jenuh, mempertahankan pelanggan yang sudah ada jauh lebih efisien secara biaya dibandingkan strategi akuisisi pelanggan baru (Provost dan Fawcett, 2013). Oleh karena itu, Churn Prediction menjadi instrumen krusial bagi perusahaan untuk mengidentifikasi individu yang memiliki risiko tinggi untuk meninggalkan layanan sebelum kontrak mereka berakhir (Kotu dan Deshpande, 2019).

Secara metodologis, prediksi churn umumnya dirumuskan sebagai masalah klasifikasi biner dalam *supervised learning* (Provost dan Fawcett, 2013). Proses ini melibatkan penggunaan data historis (seperti pola penggunaan, riwayat interaksi bantuan, dan profil tagihan) untuk membangun model yang mampu membedakan antara pelanggan yang bertahan (*stay*) dan pelanggan yang akan keluar (*leave*) (Kotu dan Deshpande, 2019). Output dari pemodelan ini berupa skor probabilitas, yang memungkinkan departemen pemasaran untuk melakukan intervensi proaktif, seperti menawarkan program loyalitas atau paket khusus untuk meminimalkan potensi kerugian finansial akibat hilangnya pelanggan bernilai tinggi (Kotu dan Deshpande, 2019; Provost dan Fawcett, 2013).

2.2.2 Customer Segmentation

Customer segmentation adalah proses krusial dalam sains data untuk mengeksplorasi dan menemukan kelompok-kelompok bermakna (klaster) di mana individu dalam satu kelompok memiliki kemiripan ciri yang tinggi, namun sangat berbeda dengan individu di kelompok lain (Kotu dan Deshpande, 2019). Di industri telekomunikasi, segmentasi dilakukan untuk mengidentifikasi "pelanggan prototipe" (deskripsi pelanggan tipikal) berdasarkan pola penggunaan produk (*usage patterns*) agar strategi retensi dan pesan pemasaran dapat dipersonalisasi secara efektif (Kotu dan Deshpande, 2019).

Pendekatan Sains Data dalam Segmentasi

Secara metodologis, segmentasi dalam sains data terbagi menjadi dua pendekatan utama:

1. **Unsupervised Segmentation (Clustering):** Menemukan pengelompokan alami dalam data tanpa didorong oleh variabel target tertentu untuk memahami struktur dasar populasi (Provost dan Fawcett, 2013).
2. **Supervised Segmentation:** Membagi populasi berdasarkan karakteristik target spesifik yang ingin diprediksi, seperti risiko pembatalan layanan atau *churn* (Provost dan Fawcett, 2013).

Matriks Perilaku dan Ukuran Tendensi Sentral

Dalam membangun **Behavioral Matrix** (Matriks Perilaku), variabel numerik seperti durasi panggilan, penggunaan data, dan beban tagihan digunakan untuk membedakan interaksi pelanggan secara aktual (Kotu dan Deshpande, 2019). Pembagian kuadran dalam matriks ini memerlukan ambang batas (*threshold*) yang ditentukan melalui ukuran tendensi sentral.

Penggunaan nilai **Median** sangat direkomendasikan sebagai titik potong dibandingkan rata-rata (*mean*) karena sifatnya yang **tangguh (robust)** (Ratnawati, 2019). Median tidak sensitif terhadap data pencilan (*outlier*), sehingga mampu memberikan representasi titik pusat yang lebih akurat pada distribusi data yang miring atau tidak merata (Ratnawati, 2019).

Package Mismatch dan Hubungannya dengan Churn

Pemetaan pelanggan ke dalam persona (seperti *Internet Enthusiast* atau *Power User*) sangat penting untuk mendeteksi fenomena **package mismatch** atau **wasted value** (Provost dan Fawcett, 2013). Kondisi ini terjadi ketika pelanggan membayar fasilitas yang tidak mereka gunakan secara maksimal, yang sering kali menjadi pemicu utama ketidakpuasan dan keputusan pelanggan untuk berhenti berlangganan atau melakukan **churn** (Provost dan Fawcett, 2013).

2.2.3 Kualitas Layanan & Sensitivitas Harga

Kualitas layanan merupakan faktor determinan dalam retensi pelanggan yang diukur melalui berbagai sinyal interaksi, seperti jumlah tiket bantuan (*support tickets*) dan kategori umpan balik (*feedback*) pelanggan (Kotu dan Deshpande, 2019). Dalam perspektif sains data, pemantauan terhadap indikator kualitas ini sangat penting untuk mengidentifikasi titik kritis (*pain points*) yang dapat memicu ketidakpuasan sebelum pelanggan memutuskan untuk berhenti berlangganan (Ratnawati, 2024; Provost dan Fawcett, 2013). Analisis yang mendalam terhadap pola data interaksi membantu perusahaan menemukan efisiensi operasional dan meningkatkan nilai layanan yang ditawarkan (Ratnawati, 2024).

Sensitivitas harga mengacu pada sejauh mana beban finansial, yang direpresentasikan oleh tagihan bulanan (*monthly bill*), memengaruhi loyalitas pelanggan (Provost dan Fawcett, 2013). Di industri telekomunikasi, fenomena **wasted value** terjadi saat pelanggan merasa membayar mahal untuk fasilitas yang tidak mereka gunakan secara optimal, yang secara signifikan meningkatkan sensitivitas mereka terhadap harga (Kotu dan Deshpande, 2019). Teori ekonomi data menunjukkan bahwa pelanggan yang memiliki loyalitas rendah cenderung sangat sensitif terhadap fluktuasi harga atau beban tagihan yang tinggi (Provost dan Fawcett, 2013). Oleh karena itu, pemahaman terhadap elastisitas harga pada setiap segmen memungkinkan perusahaan untuk mengoptimalkan strategi penentuan harga (*pricing*

strategy) guna meminimalkan angka *churn* dan memaksimalkan nilai seumur hidup pelanggan (Provost dan Fawcett, 2013; Kotu dan Deshpande, 2019).

2.3.3 Customer Satisfaction

Customer satisfaction atau kepuasan pelanggan merupakan salah satu konsep utama dalam pemasaran yang menggambarkan tingkat kesesuaian antara harapan pelanggan sebelum menggunakan suatu produk atau layanan dengan pengalaman aktual yang diperoleh setelah penggunaan. Apabila kinerja layanan memenuhi atau bahkan melampaui harapan pelanggan, maka pelanggan akan merasa puas. Sebaliknya, apabila kinerja layanan berada di bawah harapan, pelanggan akan mengalami ketidakpuasan yang berpotensi memengaruhi perilaku mereka terhadap perusahaan, seperti mengurangi penggunaan layanan atau berpindah ke penyedia lain. Konsep ini telah menjadi salah satu indikator penting dalam mengevaluasi kualitas layanan serta keberhasilan perusahaan dalam mempertahankan pelanggan.

Menurut Kotler dan Keller (2016), *customer satisfaction* adalah perasaan senang atau kecewa yang muncul setelah pelanggan membandingkan persepsi terhadap kinerja suatu produk atau layanan dengan harapan yang dimilikinya. Walaupun definisi tersebut merupakan teori klasik yang masih banyak dijadikan acuan, penelitian terbaru menunjukkan bahwa customer satisfaction tidak lagi hanya dipengaruhi oleh kualitas produk, tetapi juga dipengaruhi oleh pengalaman pelanggan secara menyeluruh (*customer experience*), kemudahan memperoleh layanan, responsivitas perusahaan, kualitas komunikasi, hingga kemampuan perusahaan dalam menyelesaikan keluhan pelanggan.

Meta-analisis yang dilakukan oleh Vikas Mittal dan rekan-rekannya menganalisis 245 penelitian dengan lebih dari satu juta responden dan menemukan bahwa customer satisfaction memiliki hubungan positif yang signifikan terhadap loyalitas pelanggan, retensi pelanggan, pembelian ulang (*repurchase intention*), komunikasi positif dari pelanggan (*word of mouth*), peningkatan pengeluaran pelanggan, serta kinerja keuangan perusahaan. Temuan tersebut memperlihatkan bahwa perusahaan yang berhasil menjaga kepuasan pelanggan memiliki peluang lebih besar untuk mempertahankan pelanggan dalam jangka panjang sekaligus meningkatkan profitabilitas perusahaan.

Dalam industri telekomunikasi, kepuasan pelanggan menjadi salah satu faktor yang paling menentukan keberhasilan perusahaan dalam mempertahankan pelanggan. Pelanggan umumnya mengevaluasi kualitas jaringan, kestabilan koneksi internet, kualitas panggilan telepon, kecepatan penanganan komplain, transparansi sistem penagihan, serta pelayanan customer service sebelum memutuskan untuk tetap menggunakan layanan atau berpindah ke operator lain. Oleh karena itu, perusahaan telekomunikasi harus mampu menjaga kualitas layanan secara konsisten agar tingkat kepuasan pelanggan tetap tinggi.

Pada penelitian ini, customer satisfaction menjadi landasan teori dalam menganalisis kualitas layanan perusahaan telekomunikasi. Variabel seperti *support_tickets*, *customer_feedback*, dan *contract_type* digunakan untuk menggambarkan pengalaman

pelanggan terhadap layanan perusahaan. Banyaknya keluhan pelanggan maupun tingginya frekuensi tiket dukungan diperkirakan menunjukkan tingkat kepuasan yang lebih rendah sehingga dapat meningkatkan kemungkinan pelanggan melakukan churn.

2.2.4 Customer Retention

Customer retention merupakan kemampuan perusahaan dalam mempertahankan pelanggan agar tetap menggunakan produk atau layanan dalam jangka waktu yang panjang. Berbeda dengan customer acquisition yang berfokus pada memperoleh pelanggan baru, customer retention lebih menitikberatkan pada upaya membangun hubungan jangka panjang sehingga pelanggan tetap loyal terhadap perusahaan. Strategi retensi pelanggan menjadi semakin penting karena mempertahankan pelanggan yang sudah ada umumnya membutuhkan biaya yang lebih rendah dibandingkan memperoleh pelanggan baru.

Customer retention dipengaruhi oleh berbagai faktor, antara lain kepuasan pelanggan, kualitas layanan, kepercayaan pelanggan, komunikasi perusahaan, pengalaman pelanggan, serta hubungan emosional yang terbentuk antara pelanggan dengan perusahaan. Penelitian systematic literature review oleh Albérico Rosário menunjukkan bahwa relationship marketing berperan penting dalam meningkatkan customer retention melalui peningkatan kepuasan pelanggan, komitmen, kepercayaan, dan kualitas komunikasi antara perusahaan dengan pelanggan.

Penelitian lain menunjukkan bahwa pengalaman pelanggan (customer experience) yang positif memiliki pengaruh yang signifikan terhadap retensi pelanggan. Selain itu, perusahaan yang mampu menciptakan hubungan emosional dengan pelanggan memiliki kemungkinan lebih besar untuk mempertahankan pelanggan dibandingkan perusahaan yang hanya mengandalkan kontrak atau biaya perpindahan (switching cost). Dengan demikian, customer retention tidak hanya dipengaruhi oleh faktor ekonomi, tetapi juga dipengaruhi oleh pengalaman dan hubungan yang dibangun selama pelanggan menggunakan layanan perusahaan.

Dalam industri telekomunikasi, customer retention menjadi salah satu indikator utama keberhasilan perusahaan karena tingkat persaingan yang tinggi membuat pelanggan dapat dengan mudah berpindah ke operator lain. Oleh sebab itu, perusahaan perlu memahami faktor-faktor yang menyebabkan pelanggan tetap bertahan maupun meninggalkan perusahaan sehingga strategi retensi dapat disusun secara lebih efektif.

Pada penelitian ini, customer retention menjadi dasar dalam mengevaluasi bagaimana kualitas layanan, jumlah komplain pelanggan, jenis kontrak, serta umpan balik pelanggan dapat memengaruhi keputusan pelanggan untuk tetap menggunakan layanan perusahaan. Analisis tersebut diharapkan dapat memberikan rekomendasi bagi perusahaan dalam meningkatkan strategi retensi pelanggan dan menekan tingkat customer churn.

2.2.5 Customer Churn

Customer churn merupakan kondisi ketika pelanggan memutuskan untuk menghentikan penggunaan suatu produk atau layanan dalam periode tertentu. Dalam industri telekomunikasi, churn biasanya ditandai dengan pelanggan yang menutup layanan, berpindah ke operator lain, atau tidak lagi melakukan penggunaan layanan dalam jangka waktu tertentu. Tingginya tingkat churn menjadi salah satu tantangan utama perusahaan karena berdampak langsung terhadap penurunan pendapatan, meningkatnya biaya akuisisi pelanggan baru, serta berkurangnya profitabilitas perusahaan.

Systematic literature review yang dilakukan oleh Hugo Ribeiro mengidentifikasi bahwa customer satisfaction, service quality, switching cost, usia pelanggan, jenis kelamin, serta berbagai karakteristik perilaku pelanggan merupakan determinan utama yang memengaruhi customer churn pada industri telekomunikasi. Penelitian tersebut juga menjelaskan bahwa churn dipengaruhi oleh kombinasi faktor perilaku pelanggan dan karakteristik yang tersimpan dalam sistem manajemen pelanggan perusahaan, sehingga analisis data menjadi sangat penting dalam memahami penyebab pelanggan berpindah layanan.

Perkembangan teknologi data science dan machine learning memungkinkan perusahaan melakukan prediksi customer churn secara lebih akurat. Berbagai penelitian menunjukkan bahwa analisis terhadap pola penggunaan internet, durasi panggilan, besarnya tagihan bulanan, jumlah tiket dukungan, maupun karakteristik pelanggan mampu membantu perusahaan mengidentifikasi pelanggan yang memiliki risiko tinggi untuk melakukan churn sehingga tindakan retensi dapat dilakukan lebih awal.

Dalam konteks penelitian ini, customer churn menjadi variabel target yang dianalisis menggunakan pendekatan exploratory data analysis (EDA). Variabel-variabel seperti **support_tickets**, **customer_feedback**, **contract_type**, dan **city** dianalisis untuk mengetahui hubungan antara kualitas layanan dengan kemungkinan pelanggan melakukan churn. Hasil analisis diharapkan dapat menjadi dasar dalam memberikan rekomendasi strategis kepada perusahaan telekomunikasi untuk meningkatkan kualitas layanan, memperkuat retensi pelanggan, serta menurunkan tingkat customer churn.

2.2.6 Pricing

Pricing atau penetapan harga menentukan pendapatan (*revenue*) dan profitabilitas suatu perusahaan. Harga bukan sekadar angka nominal yang harus dibayar oleh konsumen, melainkan representasi nilai yang dipertukarkan untuk mendapatkan suatu manfaat layanan. Harga berfungsi sebagai indikator kualitas dan beban keuangan dalam pandangan konsumen. Ketika situasi makroekonomi suatu negara bergejolak, seperti yang terjadi di Pakistan ketika tingkat inflasi mencapai 11,7%, daya beli riil masyarakat akan terganggu. Kondisi ini menyebabkan sensitivitas harga yang lebih tinggi. Sensitivitas harga mengacu pada seberapa besar pengaruh perubahan harga atau tarif pengeluaran pada keputusan pembelian pelanggan. Pelanggan yang sangat sensitif terhadap harga akan sangat sensitif terhadap kenaikan biaya

bulanan yang lebih besar daripada rasio bill-to-income mereka. Akibatnya, penyesuaian tarif yang tidak rasional akan menyebabkan pelanggan berhenti berlangganan dengan cepat.

2.2.7 Customer Value

Nilai pelanggan, juga dikenal sebagai "nilai pelanggan", didefinisikan sebagai penilaian menyeluruh konsumen tentang seberapa bermanfaat atau bermanfaat suatu produk atau layanan berdasarkan persepsi mereka tentang keuntungan yang mereka terima (manfaat) dibandingkan dengan biaya yang mereka korbankan (biaya). Secara matematis, nilai pelanggan dirumuskan sebagai berikut:

$$\text{Customer Value} = \frac{\text{Perceived Benefits}}{\text{Perceived Costs}}$$

2.2.8 Customer Lifetime Value

Jumlah nilai tunai atau proyeksi keuntungan bersih yang akan dihasilkan oleh seorang pelanggan untuk perusahaan selama jangka waktu hubungan kontraktual (jangka waktu hubungan). Pelanggan dilihat oleh CLV sebagai aset jangka panjang, bukan komoditas transaksi sekali beli. Nilai CLV dalam industri telekomunikasi yang berbasis langganan (yang dikenal sebagai "industri berbasis langganan") sangat bergantung pada seberapa baik suatu perusahaan mempertahankan pelanggan dan mengurangi laju kehilangan pelanggan. Formula dasar untuk menemukan nilai CLV biasanya terdiri dari komponen berikut:

$$\text{CLV} = \text{Average Revenue Per User} \times \text{Customer Lifetime} - \text{Customer Acquisition Cost}$$

2.3 Metodologi Data & Analysis

2.3.1 Data Preprocessing

Pra-pemrosesan data (*data preprocessing*) adalah fase krusial dalam siklus sains data yang bertujuan untuk menyaring dan menyiapkan data mentah agar siap digunakan dalam tahap pemodelan (Kotu dan Deshpande, 2019). Data dalam dunia nyata sering kali bersifat "kotor", yang ditandai dengan ketidaklengkapan (*missing values*), adanya gangguan (*noisy data*), serta ketidakkonsistenan format (Ratnawati, 2020). Kegagalan dalam menangani kualitas data ini akan berdampak langsung pada akurasi model, sesuai dengan prinsip *garbage in, garbage out* (Provost dan Fawcett, 2013).

Tugas utama dalam pemrosesan awal meliputi empat tahap (Ratnawati, 2020; Kotu dan Deshpande, 2019):

1. Pembersihan Data (*Data Cleansing*): Menangani nilai yang hilang, menghaluskan data yang bising, serta mengidentifikasi dan menangani pencilan (*outlier*).
2. Integrasi Data: Menggabungkan data dari berbagai sumber atau basis data yang berbeda menjadi satu kesatuan.
3. Transformasi Data: Melakukan normalisasi, standarisasi, atau pengkodean (*encoding*) variabel kategori menjadi numerik agar sesuai dengan kebutuhan algoritma.
4. Reduksi Data: Mengurangi volume data tanpa menghilangkan informasi penting guna meningkatkan efisiensi komputasi.

2.3.2 Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA) adalah pendekatan analisis data yang bertujuan untuk memahami karakteristik dasar, struktur, dan pola tersembunyi di dalam dataset (Kotu dan Deshpande, 2019). Proses ini melibatkan penggunaan statistik deskriptif dan teknik visualisasi untuk mendeteksi anomali, menguji hipotesis, dan memeriksa asumsi sebelum dilakukan analisis yang lebih kompleks (Provost dan Fawcett, 2013). Secara praktis, EDA membantu peneliti menjawab pertanyaan mengenai nilai tipikal suatu atribut (tendensi sentral) dan tingkat persebarannya (*variabilitas*) (Kotu dan Deshpande, 2019).

Alur kerja EDA umumnya mengikuti sebuah Roadmap sembilan langkah, yang mencakup pengorganisasian data, penghitungan titik pusat (median/mean), analisis variabilitas, visualisasi distribusi, hingga pemahaman hubungan antar-atribut melalui matriks korelasi (Ratnawati, 2025; Kotu dan Deshpande, 2019). Melalui EDA, peneliti dapat memvalidasi apakah data telah memenuhi persyaratan untuk menjawab tujuan bisnis yang telah ditetapkan di awal proyek (Ratnawati, 2024).

2.3.2 Data Visualization

Visualisasi data didefinisikan sebagai metode untuk mengekspresikan data dalam bentuk visual abstrak guna mempermudah pemahaman terhadap hubungan antar-atribut yang kompleks (Kotu dan Deshpande, 2019). Penglihatan manusia memiliki kemampuan kognitif yang kuat untuk mengenali pola dan tren dengan cepat ketika informasi disajikan secara visual dibandingkan dalam bentuk tabel numerik mentah (Kotu dan Deshpande, 2019).

Beberapa teknik visualisasi utama yang umum digunakan dalam sains data meliputi (Ratnawati, 2020; Kotu dan Deshpande, 2019):

- Histogram: Digunakan untuk menunjukkan frekuensi kemunculan nilai dan bentuk distribusi suatu variabel tunggal (*univariate*).
- Boxplot: Berguna untuk melihat ringkasan statistik (median, kuartil) serta mendeteksi keberadaan *outlier* secara visual.
- Scatterplot: Digunakan untuk mengeksplorasi hubungan atau korelasi antara dua variabel numerik.

Pentingnya visualisasi ditegaskan melalui fenomena Anscombe's Quartet, yang membuktikan bahwa kumpulan data dengan properti statistik deskriptif yang identik dapat

memiliki distribusi yang sangat berbeda ketika ditampilkan dalam bentuk grafik (Kotu dan Deshpande, 2019). Oleh karena itu, visualisasi merupakan alat eksplorasi yang tidak terpisahkan dalam memastikan integritas analisis data.

2.4 Teknologi

2.4.1 Bahasa Pemrograman Python

Python merupakan bahasa pemrograman tingkat tinggi (*high-level programming language*) yang dikembangkan dengan tujuan memberikan sintaks yang sederhana, mudah dipahami, serta mendukung berbagai paradigma pemrograman, seperti *procedural programming*, *object-oriented programming*, dan *functional programming*. Python banyak digunakan dalam berbagai bidang, termasuk pengembangan perangkat lunak, otomatisasi sistem, kecerdasan buatan (*Artificial Intelligence*), *Machine Learning*, hingga *Data Science* karena memiliki ekosistem pustaka (*library*) yang sangat lengkap dan komunitas pengguna yang besar (Python Software Foundation, 2024).

Dalam bidang *Data Science*, Python menjadi salah satu bahasa pemrograman yang paling populer karena mampu mengolah data dalam jumlah besar secara efisien serta menyediakan berbagai pustaka yang mendukung proses analisis data, visualisasi, hingga pembangunan model *Machine Learning*. Menurut Van Rossum dan Drake (2021), keunggulan Python terletak pada keterbacaan sintaks (*readability*), kemudahan integrasi dengan berbagai teknologi, serta fleksibilitasnya dalam menangani berbagai kebutuhan komputasi ilmiah.

Pada penelitian ini, Python digunakan sebagai bahasa pemrograman utama untuk melakukan seluruh proses pengolahan data, mulai dari pembacaan dataset (*data loading*), *data preprocessing*, *feature engineering*, *Exploratory Data Analysis (EDA)*, visualisasi data, hingga analisis hubungan antar variabel. Penggunaan Python memungkinkan seluruh tahapan analisis dilakukan secara terstruktur, terdokumentasi dengan baik, serta mudah direproduksi (*reproducible research*), sehingga mendukung kualitas penelitian berbasis data (Python Software Foundation, 2024).

2.4.2 Library Pandas

Pandas merupakan pustaka (*library*) Python yang dirancang khusus untuk melakukan manipulasi dan analisis data terstruktur. Pandas menyediakan dua struktur data utama, yaitu *Series* untuk data satu dimensi dan *DataFrame* untuk data dua dimensi yang menyerupai tabel pada basis data maupun spreadsheet. Struktur tersebut memungkinkan pengguna melakukan proses pengolahan data secara efisien, seperti membaca data, membersihkan data, melakukan transformasi, agregasi, penggabungan (*merge*), hingga analisis statistik deskriptif (McKinney, 2022).

Dalam proses *Data Science*, Pandas menjadi salah satu library yang paling penting karena hampir seluruh tahapan awal analisis data dilakukan menggunakan *DataFrame*. Berbagai fungsi seperti *read_csv()*, *info()*, *describe()*, *groupby()*, *merge()*, dan *pivot_table()*

memungkinkan proses eksplorasi data dilakukan secara sistematis dan efisien (Pandas Development Team, 2025).

Pada penelitian ini, Pandas digunakan untuk memuat dataset pelanggan telekomunikasi, melakukan pemeriksaan struktur data, mendeteksi nilai yang hilang (*missing values*), menghapus data duplikat, melakukan *feature engineering*, mengelompokkan data berdasarkan kategori tertentu, hingga menghasilkan tabel ringkasan yang digunakan dalam proses Exploratory Data Analysis (EDA).

2.4.3 Library Numpy

NumPy (Numerical Python) merupakan pustaka komputasi numerik yang menyediakan struktur data berupa ndarray (*N-dimensional array*) untuk menyimpan dan memproses data numerik secara efisien. NumPy dirancang agar mampu melakukan operasi matematika dan aljabar linear dengan performa tinggi dibandingkan struktur data bawaan Python karena sebagian besar implementasinya menggunakan bahasa C (Harris et al., 2020).

Selain menyediakan operasi matematika dasar, *NumPy* juga mendukung berbagai fungsi statistik, manipulasi matriks, pembangkitan bilangan acak (random number generation), serta operasi logika yang banyak digunakan dalam analisis data dan Machine Learning. Oleh karena itu, sebagian besar library analisis data di Python, termasuk Pandas, Scikit-learn, dan Matplotlib, dibangun di atas *NumPy* (NumPy Developers, 2025).

Dalam penelitian ini, *NumPy* digunakan untuk mendukung proses perhitungan numerik selama tahap preprocessing, seperti perhitungan median, kuartil, Interquartile Range (IQR), penanganan outlier, serta berbagai operasi matematika yang diperlukan dalam proses feature engineering.

2.4.4 Library Matplotlib

Matplotlib merupakan library visualisasi data dua dimensi yang paling banyak digunakan dalam ekosistem Python. Library ini menyediakan berbagai fungsi untuk menghasilkan grafik seperti line chart, bar chart, scatter plot, histogram, pie chart, hingga box plot. Visualisasi tersebut membantu peneliti memahami pola distribusi data, mengidentifikasi hubungan antar variabel, serta mendeteksi keberadaan outlier secara visual (Hunter, 2007).

Salah satu keunggulan *Matplotlib* adalah fleksibilitasnya dalam mengatur hampir seluruh aspek visualisasi, seperti warna, ukuran gambar, label sumbu, judul grafik, legenda, hingga anotasi. Kemampuan tersebut menjadikan Matplotlib sebagai fondasi utama berbagai library visualisasi lain di Python, termasuk Seaborn (Matplotlib Development Team, 2025).

Pada penelitian ini, Matplotlib digunakan untuk membuat berbagai visualisasi dasar selama proses *Exploratory Data Analysis*, seperti histogram, box plot, bar chart, dan pie chart guna memberikan gambaran mengenai karakteristik pelanggan serta distribusi variabel yang digunakan dalam analisis.

2.4.5 Library Seaborn

Seaborn merupakan library visualisasi statistik berbasis Matplotlib yang dikembangkan untuk menghasilkan grafik dengan tampilan yang lebih informatif dan estetik. Seaborn menyediakan fungsi visualisasi tingkat tinggi (*high-level interface*) yang memudahkan pengguna dalam membuat grafik statistik tanpa perlu melakukan banyak konfigurasi secara manual (Waskom, 2021).

Library ini mendukung berbagai jenis visualisasi yang umum digunakan dalam analisis data, seperti countplot, barplot, boxplot, violin plot, pairplot, heatmap, dan scatterplot. Selain itu, Seaborn memiliki kemampuan untuk secara otomatis menghitung agregasi statistik, seperti rata-rata dan interval kepercayaan (*confidence interval*), sehingga mempermudah proses eksplorasi data (Seaborn Development Team, 2025).

Dalam penelitian ini, Seaborn digunakan untuk menghasilkan berbagai visualisasi statistik pada tahap *General Exploratory Data Analysis (EDA)* maupun *Specific EDA*. Visualisasi tersebut meliputi distribusi pelanggan berdasarkan karakteristik demografi, hubungan antara variabel terhadap customer churn, analisis support tickets, jenis kontrak pelanggan, hingga heatmap korelasi antar variabel. Penggunaan Seaborn membantu proses interpretasi data menjadi lebih mudah dipahami dan mendukung penyusunan rekomendasi bisnis berdasarkan hasil analisis.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis Penelitian

Penelitian ini menggunakan jenis penelitian kuantitatif berbasis eksperimental terapan di bidang data sains. Eksperimen difokuskan pada pemodelan prediktif klasifikasi biner, di mana algoritma dilatih untuk mengenali pola perilaku historis, atribut demografi, kondisi finansial, tingkat pemanfaatan layanan, serta sentimen tertulis dari pelanggan guna mengklasifikasikan status akhir pelanggan ke dalam dua kelas diskrit: apakah pelanggan akan mempertahankan layanan (*retained*) atau berhenti berlangganan (*churn*).

3.2 Dataset

Dataset yang melandasi seluruh rangkaian eksperimen ini bertajuk Telecom Customer Churn Feature Engineering Dataset yang diperoleh dari platform kompetisi data sains Kaggle dan dimuat secara langsung melalui repositori GitHub resmi Kelompok 2. Dataset mentah ini mencakup total basis data sebanyak **1.200 baris observasi** dengan **15 kolom atribut awal**. Karakteristik data merupakan kombinasi dari tipe numerik kontinu, numerik diskrit, kategorikal nominal, kategorikal ordinal, serta data tekstual tidak terstruktur (*unstructured text*).

Tabel 3.1 Struktur Spesifikasi Atribut Dataset Awal

No	Nama Fitur	Tipe Data	Deskripsi Akademis & Fungsional
1	customer_id	Integer / Object	Identitas unik numerik setiap individu pelanggan (rentang 10001–11200). Berfungsi murni sebagai penanda (<i>identifier</i>) dan tidak memiliki nilai prediktif sejalan prinsip kausalitas, sehingga dieksklusi dalam pemodelan.
2	signup_date	String / Date	Tanggal pencatatan registrasi awal pelanggan (rentang waktu 1 Januari 2019 hingga 14 April 2022). Digunakan sebagai variabel basis untuk menghitung durasi retensi lewat rekayasa fitur temporal.
3	age	Integer	Representasi usia biologis pelanggan dalam satuan tahun (rentang 18–69 tahun, rata-rata 43,5 tahun). Berguna untuk pemetaan segmentasi demografi.
4	gender	Kategorikal	Jenis kelamin pelanggan dengan variasi nilai binomial (<i>Male</i> dan <i>Female</i>).
5	city	Kategorikal	Variabel spasial yang menunjukkan kota domisili operasional pelanggan (contoh: Multan, Peshawar, Gujranwala, Lahore, Hyderabad).

No	Nama Fitur	Tipe Data	Deskripsi Akademis & Fungsional
6	education_level	Categorikal	Tingkat pendidikan formal terakhir pelanggan (<i>Primary, Secondary, Bachelor, Master</i>) yang mencerminkan profil latar belakang sosial.
7	employment_statuses	Categorikal	Status pekerjaan atau okupasi aktif dari pelanggan (<i>Employed, Self-employed, Student, Unemployed</i>).
8	monthly_income	Float	Besaran pendapatan finansial bulanan riil dari pelanggan. Berfungsi sebagai proksi daya beli dan kapasitas ekonomi.
9	monthly_bill	Float	Total nilai tagihan finansial yang dibebankan atas pemakaian layanan telekomunikasi setiap bulannya.
10	internet_usage_gb	Float	Volume konsumsi kuota data internet pelanggan dalam satuan Gigabyte (GB) sepanjang siklus penagihan berjalan.
11	call_minutes	Float	Akumulasi durasi komunikasi suara (panggilan telepon) yang dihabiskan pelanggan dalam satuan menit.
12	contract_type	Categorikal	Metode ikatan kontrak hukum penagihan layanan yang dipilih (<i>Monthly, 6-Month, 12-Month</i>).
13	support_tickets	Integer	Kuantitas berkas keluhan resmi atau tiket aduan yang diajukan pelanggan ke bagian pusat bantuan pelanggan (<i>customer support</i>).
14	customer_feedback	Text	Ulasan kualitatif naratif teks bebas yang ditulis langsung oleh pelanggan mengenai impresi atau kendala operasional layanan.
15	churn	Binary	Variabel Target (Label Klasifikasi) di mana nilai 1 merepresentasikan kejadian pelanggan berhenti berlangganan (<i>Churn</i>), sedangkan nilai 0 merepresentasikan pelanggan tetap aktif (<i>Retained</i>).

1. Pilar Analisis Segmentasi Aktivitas & Perilaku Pelanggan (*Segmentation*)

Pilar ini memetakan karakteristik perilaku pelanggan berdasarkan tingkat penggunaan atau konsumsi riil terhadap layanan.

Fokus Atribut:

- **internet_usage_gb_capped**: Volume konsumsi kuota data internet (setelah pembersihan *outlier*).
- **call_minutes_capped**: Akumulasi durasi panggilan telepon (setelah pembersihan *outlier*).
- **monthly_bill_capped**: Total nilai tagihan finansial bulanan (setelah pembersihan *outlier*).

- churn: Variabel target biner (indikator kehilangan atau bertahanya pelanggan).

2. Pilar Analisis Layanan dan Kendala Pelanggan (*Service & Pain Points*)

Pilar ini bertujuan untuk mengidentifikasi tingkat kepuasan pelanggan, hambatan operasional, aspek kontrak, serta titik kritis (*pain points*) pemicu *churn*.

Fokus Atribut:

- support_tickets: Frekuensi aduan resmi pelanggan sebagai indikator kendala operasional (*pain points*).
- contract_type: Bentuk ikatan komitmen waktu pelanggan (*Monthly, 6-Month, 12-Month*).
- city: Lokasi geografis pelanggan untuk mendeteksi kendala layanan berbasis regional.
- customer_feedback: Ulasan naratif jujur pelanggan untuk menangkap kata kunci kritis masalah.
- churn: Variabel target biner (indikator kehilangan atau bertahanya pelanggan).


3. Pilar Analisis Sensitivitas Harga dan Kondisi Finansial (*Financial Sensitivity*)

Pilar ini dirancang untuk menggali profil ekonomi pelanggan serta sensitivitas mereka terhadap struktur tarif layanan di berbagai wilayah geografis.

Fokus Atribut:

- monthly_bill_capped: Beban pengeluaran tagihan bulanan.
- monthly_income_scaled: Kapasitas pendapatan bulanan pelanggan.
- financial_risk: Indikator biner tekanan finansial jika tagihan melebihi pendapatan.
- age_scaled: Korelasi rentang usia dengan kestabilan finansial.
- city_Faisalabad, city_Gujranwala, city_Hyderabad, city_Islamabad, city_Karachi, city_Lahore, city_Multan, city_Peshawar, city_Quetta, city_Rawalpindi, dan city_Sialkot: Atribut spasial kota hasil *One-Hot Encoding*.
- churn: Variabel target biner

3.3 Tahapan Penelitian



3.4 Data Preprocessing

Preprocessing data difungsikan untuk mentransformasikan data mentah yang rawan distorsi menjadi representasi yang optimal bagi model komputer. Berdasarkan implementasi pemrograman pada repositori notebook kelompok, rincian operasional yang diterapkan mencakup:

a. Missing Value Audit

Pengecekan menyeluruh dijalankan menggunakan fungsi pemrograman terintegrasi untuk mendeteksi keberadaan nilai kosong di seluruh baris data. Hasil audit mengonfirmasi bahwa dataset ini bersih sempurna dari data kosong (0 baris *missing values*), menghilangkan kebutuhan untuk imputasi statistik (seperti rata-rata atau modus).

```
missing = df.isnull().sum()
missing_pct = (missing / len(df) * 100).round(2)
missing_df = pd.DataFrame({
    'Jumlah Missing': missing,
    'Persentase (%)': missing_pct
})

print("Pemeriksaan Missing values per kolom:")
print("-" * 45)
if missing_df['Jumlah Missing'].sum() == 0:
    print("Tidak ditemukan missing values pada seluruh kolom dataset.")
    print("Dataset dalam kondisi lengkap dan tidak memerlukan imputasi.")
else:
    display(missing_df[missing_df['Jumlah Missing'] > 0].sort_values('Jumlah Missing', ascending=False))
```

b. Duplicate Record Check

Evaluasi baris berulang dijalankan untuk mengeliminasi potensi bias replikasi sampel. Hasil pengujian menunjukkan tidak terdapat data duplikat sama sekali (0 baris duplikat), menegaskan keselarasan data observasi secara individual. Berikut kodenya:

```
n_dup = df.duplicated().sum()
print(f"Jumlah baris duplikat: {n_dup}")

if n_dup > 0:
    df.drop_duplicates(inplace=True)
    print(f"{n_dup} baris duplikat berhasil dihapus.")
    print(f"Shape setelah pembersihan: {df.shape}")
else:
    print("Tidak ditemukan baris duplikat. Tidak ada tindakan yang diperlukan.")

print(f"Jumlah baris setelah pengecekan duplikat: {len(df)}")
```

```
Jumlah baris duplikat: 0
Tidak ditemukan baris duplikat. Tidak ada tindakan yang diperlukan.
Jumlah baris setelah pengecekan duplikat: 1200
```

c. Penanganan Outlier Eksstrem (Capping/Winsorization)

Analisis distribusi menunjukkan adanya ekor panjang ke kanan (*right-skewed distribution*) pada variabel finansial dan pemakaian, seperti *monthly_income*, *monthly_bill*, *internet_usage_gb*, *call_minutes*, dan *support_tickets*. Hal ini mengonfirmasi adanya pencilan (outlier) yang valid namun ekstrem. Guna mengatasinya tanpa kehilangan baris data berharga, diterapkan metode **Interquartile Range (IQR)** dengan formulasi:

$$\text{Batas Atas} = Q3 + (1.5 \times \text{IQR})$$

Nilai-nilai ekstrim yang melampaui ambang Batas Atas tersebut disesuaikan secara proaktif ke nilai ambang batas maksimumnya (**Capping/Winsorization**) agar deviasi kuadratik tidak mengacaukan konvergensi fungsi loss algoritma klasifikasi.

```

• Fungsi untuk menerapkan capping outlier dengan IQR
def cap_outliers_iqr(df_col):
    Q1 = df_col.quantile(0.25)
    Q3 = df_col.quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR
    return df_col.clip(lower=lower_bound, upper=upper_bound)

# Kolom-kolom yang akan ditangani dengan capping
columns_to_cap = ['monthly_bill', 'internet_usage_gb', 'call_minutes', 'support_tickets']

for col in columns_to_cap:
    if col in df.columns:
        df[f'{col}_capped'] = cap_outliers_iqr(df[col])
        Q1 = df[col].quantile(0.25)
        Q3 = df[col].quantile(0.75)
        IQR = Q3 - Q1
        upper = Q3 + 1.5 * IQR
        print(f'Outlier '{col}' berhasil di-capping. Batas atas: {upper:.1f} (max asli: {df[col].max():.1f})')

print("\nRingkasan Statistik Setelah Capping:")
display(df[columns_to_cap + [f'{c}_capped' for c in columns_to_cap]].describe())

```

```

Outlier 'monthly_bill' berhasil di-capping. Batas atas: 13776.1 (max asli: 36361.0)
Outlier 'internet_usage_gb' berhasil di-capping. Batas atas: 50.1 (max asli: 82.2)
Outlier 'call_minutes' berhasil di-capping. Batas atas: 428.5 (max asli: 865.0)
Outlier 'support_tickets' berhasil di-capping. Batas atas: 5.0 (max asli: 6.0)

```

Ringkasan Statistik Setelah Capping:

	monthly_bill	internet_usage_gb	call_minutes	support_tickets	monthly_bill_capped	internet_usage_gb_capped	call_minutes_capped	support_tickets_capped
count	1200.00	1200.00	1200.00	1200.00	1200.00	1200.00	1200.00	1200.00
mean	5939.15	20.15	182.83	1.19	5709.50	19.96	179.85	1.19
std	4046.47	12.17	106.57	1.08	3226.47	11.56	96.84	1.08
min	710.00	1.10	14.00	0.00	710.00	1.10	14.00	0.00
25%	3291.75	11.10	106.00	0.00	3291.75	11.10	106.00	0.00
50%	4871.00	17.80	164.00	1.00	4871.00	17.80	164.00	1.00
75%	7485.50	26.70	235.00	2.00	7485.50	26.70	235.00	2.00
max	36361.00	82.20	865.00	6.00	13776.12	50.10	428.50	5.00

d. Feature Engineering

Guna meningkatkan derajat informatif data terhadap fenomena churn, dibentuk dua fitur turunan baru yang bersifat strategis:

- **tenure_months:** Fitur temporal ini diekstrak dengan memparsing string tanggal *signup_date*, lalu menghitung jarak masa berlangganan dalam satuan bulan terhadap titik waktu referensi proyek. Atribut ini sangat krusial mengingat pelanggan baru secara historis lebih rentan mengalami churn dibandingkan pelanggan yang telah melewati fase loyalitas awal. Setelah ekstraksi sukses, kolom asli *signup_date* dihapus demi efisiensi dimensi.
- **financial_risk:** Sebuah variabel biner indikator tekanan finansial (nilai 1 jika komponen pengeluaran *monthly_bill* bernilai lebih besar daripada kapasitas pendapatan *monthly_income*; nilai 0 jika pengeluaran berada dalam batas aman pendapatan), menangkap korelasi langsung antara beban keuangan dengan keputusan pelanggan mengakhiri kontrak.


```

# Fitur tenure_months
if 'signup_date' in df.columns:
    df['signup_date'] = pd.to_datetime(df['signup_date'])
    tanggal_referensi = pd.to_datetime('2026-06-15')
    df['tenure_months'] = (tanggal_referensi - df['signup_date']).dt.days // 30).astype(int)
    df.drop(columns=['signup_date'], inplace=True)
    print("Fitur 'tenure_months' berhasil dibuat dan kolom 'signup_date' dihapus.")
    print(f"Rentang tenure : {df['tenure_months'].min()} - {df['tenure_months'].max()} bulan")
    print(f"Kata-rata : {df['tenure_months'].mean():.1f} bulan")

# Fitur financial_risk
if 'monthly_bill' in df.columns and 'monthly_income' in df.columns:
    df['financial_risk'] = np.where(df['monthly_bill'] > df['monthly_income'], 1, 0)
    n_risk = df['financial_risk'].sum()
    print(f"Fitur 'financial_risk' berhasil dibuat.")
    print(f"Pelanggan berisiko finansial : {n_risk} ({n_risk/len(df)*100:.1f}%)")

print("\n5 baris pertama setelah pembuatan fitur baru:")
display(df.head())

```

```

Fitur 'tenure_months' berhasil dibuat dan kolom 'signup_date' dihapus.
Rentang tenure : 51 - 91 bulan
Kata-rata : 70.6 bulan

Fitur 'financial_risk' berhasil dibuat.
Pelanggan berisiko finansial : 23 (1.9%)

5 baris pertama setelah pembuatan fitur baru:

```

	age	gender	city	education_level	employment_status	monthly_income	monthly_bill	internet_usage_gb	call_minutes	contract_type	support_tickets	customer_feedback	churn	tenure_months	financial_risk
0	65	Male	Multan	Bachelor	Employed	57643.00	10049.00	5.00	52.00	6-Month	1	Coverage is poor in my location	0	91	0
1	22	Female	Peshawar	Master	Employed	18207.00	2752.00	11.90	22.00	6-Month	2	Billing issues occurred multiple times	0	91	0
2	43	Male	Gujranwala	Secondary	Employed	13075.00	3155.00	40.00	87.00	Monthly	0	Billing issues occurred multiple times	0	91	0
3	21	Male	Lahore	Secondary	Employed	30890.00	5859.00	8.50	147.00	6-Month	2	Customer support was helpful	0	90	0
4	37	Female	Hyderabad	Primary	Employed	17475.00	5106.00	3.30	103.00	12-Month	0	Coverage is poor in my location	0	90	0

e. Encoding Variabel Kategorikal dan Vektorisasi Teks

Transformasi data kualitatif dijalankan berdasarkan klasifikasi fiturnya:

- **One-Hot Encoding:** Diterapkan pada fitur kategorikal nominal dengan variasi nilai majemuk (*gender*, *city*, dan *employment_status*) menggunakan pustaka fungsi pemrograman. Langkah ini memecah kolom kategorikal menjadi kolom biner baru (0 atau 1) untuk mencegah model mengasumsikan adanya tingkatan besaran urutan (*ordinal hierarchy bias*) yang sebenarnya tidak ada pada variabel nominal.
- **Text Feature Extraction (Count Vectorizer):** Atribut naratif ulasan *customer_feedback* dibersihkan terlebih dahulu dari spasi kosong sekunder (*whitespace trimming*). Selanjutnya, teks tidak terstruktur ditransformasikan ke dalam representasi matriks kuantitatif frekuensi kemunculan kata kunci menggunakan metode **Count Vectorizer**. Teknik ini berhasil memetakan klaster kata kunci utama penyulut ketidakpuasan pelanggan ke dalam dimensi numerik terukur (seperti pendeteksian isu tingginya biaya penagihan atau keluhan buruknya sinyal jaringan).

```

# 1. Gender - binary encoding
if 'gender' in df.columns:
    df['gender'] = df['gender'].map({'Female': 0, 'Male': 1, 'female': 0, 'male': 1})
    print("Encoding 'gender': Female=0, Male=1")
    print(df['gender'].value_counts().to_string())

# 2. Education Level - ordinal encoding
edu_mapping = {'Primary': 0, 'Secondary': 1, 'Bachelor': 2, 'Master': 3, 'PhD': 4}
if 'education_level' in df.columns:
    df['education_level_encoded'] = df['education_level'].map(edu_mapping)
    print("\nEncoding 'education_level' (ordinal):")
    print(df['education_level_encoded'].value_counts().sort_index().to_string())

# 3. Contract Type - ordinal encoding
contract_mapping = {'Monthly': 0, '6-Month': 1, '12-Month': 2}
if 'contract_type' in df.columns:
    df['contract_type_encoded'] = df['contract_type'].map(contract_mapping)
    print("\nEncoding 'contract_type' (ordinal):")
    print(df['contract_type_encoded'].value_counts().sort_index().to_string())

# 4. Employment Status - one-hot encoding
if 'employment_status' in df.columns:
    df_emp_dummies = pd.get_dummies(df['employment_status'], prefix='emp', drop_first=False, dtype=int)
    df = pd.concat([df, df_emp_dummies], axis=1)
    print(f"\nOne-Hot Encoding 'employment_status': {list(df_emp_dummies.columns)}")

print("\nProses encoding selesai.")
display(df.head())

```

Encoding 'gender': Female=0, Male=1
gender
1 683
0 597
Encoding 'education_level' (ordinal):
education_level_encoded
0 165
1 384
2 422
3 249
4 68
Encoding 'contract_type' (ordinal):
contract_type_encoded
0 569
1 286
2 345
One-Hot encoding 'employment_status': ['emp_Employed', 'emp_Retired', 'emp_Self-Employed', 'emp_Student', 'emp_Unemployed']
Proses encoding selesai.
age gender city education_level employment_status monthly_income monthly_bill internet_usage_gb call_minutes contract_type support_tickets customer_feedback churn
0 65 1 Multan Bachelor Employed 57643.00 10049.00 5.80 52.00 6-Month 1 Coverage is poor in my location 0
1 22 0 Peshawar Master Employed 18207.00 2752.00 11.90 22.00 6-Month 2 Billing issues occurred multiple times 0
2 43 1 Gujranwala Secondary Employed 13075.00 3155.00 40.00 87.00 Monthly 0 Billing issues occurred multiple times 0
3 21 1 Lahore Secondary Employed 38890.00 5859.00 8.50 147.00 6-Month 2 Customer support was helpful 0

f. Feature Scaling (Normalisasi Numerik)

Guna menghindari dominasi variabel berskala besar (seperti pendapatan bernilai puluhan ribu) terhadap variabel berskala kecil (seperti kuantitas tiket aduan berdomain satuan) saat pelatihan model, seluruh fitur numerik non-kontinu seperti *age* ditransformasikan menggunakan metode Min-Max Scaling ke dalam domain rentang nilai seragam antara [0, 1].

3.5 General EDA

Tahap EDA Umum difungsikan untuk memetakan struktur dasar serta memeriksa karakteristik distribusi variabel di dalam dataset setelah melalui rangkaian proses preprocessing. Fokus utama tahapan ini berorientasi pada validasi kesiapan data sebelum didistribusikan ke tahapan pemodelan prediktif. Implementasi teknis pada tahapan ini meliputi:

a. Analisis Proporsi Variabel Target (Target Class Distribution Analysis)

Pemeriksaan tingkat keseimbangan kelas pada variabel target churn dilakukan secara visual. Metode ini diimplementasikan menggunakan fungsi `sns.countplot()` atau diagram batang frekuensi guna mendeteksi adanya indikasi class imbalance. Langkah ini penting untuk menentukan apakah model klasifikasi membutuhkan penanganan berbasis data khusus (seperti SMOTE) atau cukup mengandalkan penyesuaian metrik evaluasi pada algoritma.

b. Analisis Hubungan Variabel Kunci (Bivariate Key Features Analysis)

Eksplorasi hubungan antara variabel-variabel prediktor kunci terhadap variabel target churn dilakukan dengan teknik analisis bivariat. Secara teknis, proses ini memanfaatkan matriks visualisasi bertingkat (subplots) menggunakan kombinasi fungsi `sns.barplot()` atau `sns.boxplot()`. Metode ini digunakan untuk mengevaluasi secara visual tren sebaran data, tingkat skewness (kemencengan) pasca-capping, serta pola interaksi awal fitur-fitur penting (seperti `support_tickets`, `contract_type`, dan volume penggunaan layanan) terhadap kecenderungan churn.

c. Uji Multikolinieritas Melalui Matriks Korelasi (Correlation Matrix Mapping)

Pengujian multikolinieritas dilakukan untuk mendeteksi adanya korelasi linear yang terlalu tinggi (redundansi) antar variabel independen numerik yang dapat mengganggu stabilitas bobot model prediktif. Metode yang digunakan adalah menghitung koefisien korelasi menggunakan fungsi `.corr(method='pearson')` pada Pandas DataFrame. Hasil perhitungan koefisien tersebut kemudian dipetakan secara visual ke dalam bentuk grafik Heatmap interaktif menggunakan pustaka `sns.heatmap()` dengan parameter `annot=True` untuk mempermudah audit angka korelasi secara menyeluruh.

3.6 Specific EDA

3.6.1 Segmentasi

Sumber dan Akuisisi Data

Import library dan clean data dari github

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Tarik data bersih langsung dari GitHub
url = 'https://raw.githubusercontent.com/AIU7AgrataEleigh/Telecom-Churn-Rate_Kelompok-2/main/'
df = pd.read_csv(url)

# Melihat 5 baris data teratas
df.head()

```

	gender	churn	monthly_bill_capped	internet_usage_gb_capped	call_minutes_capped	support
0	1	0	10049.0	5.8	52.0	
1	0	0	2752.0	11.9	22.0	
2	1	0	3155.0	40.0	87.0	
3	1	0	5859.0	8.5	147.0	
4	0	0	5106.0	3.3	183.0	

5 rows x 42 columns

Visualisasi Data

- (1) pengecekan dimensi data menggunakan `df.shape`,
- (2) pengecekan tipe data setiap kolom menggunakan `df.info()`,

```

print(df.shape)

df.info()

df.describe()

```

```

... (1200, 42)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1200 entries, 0 to 1199
Data columns (total 42 columns):
#   Column                                     Non-Null Count  Dtype
---  ---                                     -
0   gender                                     1200 non-null   int64

```

(3) pengecekan missing value menggunakan `df.isna().sum()`.

```

missing = pd.DataFrame({
    "Missing Values": df.isna().sum(),
    "Persentase (%)": (df.isna().mean()*100).round(2)
})

missing

```

	Missing Values	Persentase (%)
emp_Employed	0	0.0
emp_Retired	0	0.0

Pemilihan Variabel

Variabel yang digunakan difokuskan pada tiga indikator utama yaitu aktivitas data (*internet_usage_gb_capped*), aktivitas telepon (*call_minutes_capped*), dan beban tagihan (*monthly_bill_capped*) untuk membentuk profil pelanggan, dengan variabel *churn* sebagai indikator target.


	internet_usage_gb_capped	call_minutes_capped	monthly_bill_capped	churn
0	5.8	52.0	10049.0	0
1	11.9	22.0	2752.0	0
2	40.0	87.0	3155.0	0
3	8.5	147.0	5859.0	0
4	3.3	183.0	5106.0	0

Profil Statistik

	Mean	Median	Mode	Minimum	Maximum	Range	Variance	Std Dev	Skewness	Kurtosis
internet_usage_gb_capped	19.961	17.8	50.100	1.1	50.100	49.000	1.336680e+02	11.561	0.750	-0.010
call_minutes_capped	179.851	164.0	428.500	14.0	428.500	414.500	9.377901e+03	96.840	0.761	0.089
monthly_bill_capped	5709.496	4871.0	13776.125	710.0	13776.125	13066.125	1.041013e+07	3226.474	0.971	0.258
churn	0.350	0.0	0.000	0.0	1.000	1.000	2.280000e-01	0.477	0.630	-1.606

Statistik deskriptif digunakan untuk mengetahui karakteristik pusat data, dengan penggunaan nilai median sebagai batas segmentasi yang *robust* terhadap *outlier*.

Distribusi



Visualisasi distribusi menunjukkan keragaman perilaku pelanggan, yang mengindikasikan bahwa strategi pemasaran tidak bisa disamaratakan bagi seluruh pelanggan

Metode Analisis Statistik Deskriptif & Visualisasi

	Mean	Median	Mode	Minimum	Maximum	Range	Variance	Std Dev	Skewness	Kurtosis
internet_usage_gb_capped	19.961	17.8	50.100	1.1	50.100	49.000	1.336680e+02	11.561	0.750	-0.010
call_minutes_capped	179.851	164.0	428.500	14.0	428.500	414.500	9.377901e+03	96.840	0.761	0.089
monthly_bill_capped	5709.496	4871.0	13776.125	710.0	13776.125	13066.125	1.041013e+07	3226.474	0.971	0.258
churn	0.350	0.0	0.000	0.0	1.000	1.000	2.280000e-01	0.477	0.630	-1.606

Karakteristik pusat digunakan untuk mengetahui nilai tipikal dari masing-masing variabel numerik sebelum dilakukan visualisasi data. Ukuran yang digunakan meliputi mean, median, dan mode

4.4.3 Pivot Analysis

```
pivot_summary = segmentation.groupby("churn").agg({
    "internet_usage_gb_capped": "mean",
    "call_minutes_capped": "mean",
    "monthly_bill_capped": "mean"
}).round(2)

pivot_summary.index = ["Non-Churn", "Churn"]

pivot_summary
```

	internet_usage_gb_capped	call_minutes_capped	monthly_bill_capped
Non-Churn	20.75	176.09	5270.75
Churn	18.49	186.83	6524.31

monthly_bill_capped	
customer_segment	
Traditional Communicator	5781.568182
Power User	5709.486431
Internet Enthusiast	5677.368289
Casual User	5670.199751


Analisis dilakukan menggunakan rata-rata monthly_bill sebagai indikator kontribusi pendapatan dari user

internet_usage_gb_capped call_minutes_capped monthly_bill_capped			
customer_segment			
Casual User	10.82	102.07	5670.20
Internet Enthusiast	29.34	105.42	5677.37
Power User	28.78	258.61	5709.49
Traditional Communicator	10.79	252.76	5781.57

Membentuk Customer Persona dengan K-Means Clustering Segmentasi pelanggan dilakukan menggunakan algoritma Machine Learning tanpa supervisi yaitu K-Means Clustering. Variabel yang digunakan untuk mengelompokkan pelanggan difokuskan pada fitur numerik: internet_usage_gb, call_minutes, dan monthly_bill. Sebelum diproses oleh algoritma, data distandarisasi menggunakan fungsi StandardScaler() agar seluruh variabel memiliki rentang nilai yang seimbang dan tidak ada variabel yang mendominasi perhitungan jarak.

Penentuan jumlah cluster (K) yang paling optimal dilakukan melalui metode Elbow. Berdasarkan grafik Elbow Method, nilai inersia (penurunan variansi dalam klaster) mulai melandai secara signifikan pada titik K=4, sehingga populasi pelanggan diputuskan untuk dibagi ke dalam 4 segmen utama.

...



Setelah model dilatih, terbentuk 4 Customer Persona (Segmen 0 hingga Segmen 3). Setiap segmen kemudian dianalisis nilai rata-ratanya terhadap variabel penggunaan dan status churn untuk mengetahui karakteristik perilaku serta probabilitas pelanggan meninggalkan layanan.

**

	Avg_Internet_GB	Avg_Call_Minutes	Avg_Monthly_Bill	Churn_Rate	Total_Customers
Persona					
Segmen 0	13.89	135.29	4828.89	34.0	602
Segmen 1	18.90	186.36	14950.54	57.0	121
Segmen 2	16.67	349.12	5254.60	33.0	199
Segmen 3	36.76	165.20	4911.18	29.0	278

3.6.2 Service Quality

3.6.2.1 Pendahuluan

Analisis kualitas layanan (service quality) dan titik kritis pelanggan (pain points) bertujuan mengidentifikasi faktor-faktor layanan yang berkontribusi terhadap keputusan churn. Analisis ini bersifat Specific EDA yang berfokus pada variabel-variabel berikut.

Variabel	Peran
<code>support_tickets_capped</code>	Indikator frekuensi keluhan operasional pelanggan
<code>contract_type_label</code>	Jenis kontrak sebagai cerminan barrier to exit
<code>city_name</code>	Lokasi geografis untuk mendeteksi pain point regional
<code>feedback_category</code>	Kategori sentimen umpan balik pelanggan (nominal)
<code>count_poor, count_drops, count_slow, count_expensive, count_unreliable</code>	Kata kunci spesifik dari teks <code>customer_feedback</code>
<code>tenure_months, monthly_bill_capped</code>	Variabel pendukung pada analisis interaksi
<code>churn_status</code>	Variabel target sebagai dasar pembagian populasi

Sebelum analisis dimulai, dilakukan beberapa penyesuaian terhadap dataset.

a. Rename Kolom Target

Kolom churn diubah namanya menjadi `churn_status` untuk membedakan istilah bisnis dengan nama variabel, sekaligus menjaga konsistensi penamaan di seluruh notebook.

```
In [5]:
df = df.rename(columns={'churn': 'churn_status'})
print("Kolom 'churn' berhasil diganti nama menjadi 'churn_status'.")
```

b. Pembuatan Label Jenis Kontrak

Kolom `contract_type_encoded` merupakan hasil ordinal encoding dengan pemetaan 0 = Monthly, 1 = 6 Month, 2 = 12 Month. Nilai numerik dikonversi menjadi label teks untuk meningkatkan keterbacaan hasil analisis.


```

: contract_mapping = {0: 'Monthly', 1: '6 Month', 2: '12 Month'}
df['contract_type_label'] = df['contract_type_encoded'].map(contract_mapping)

contract_order = ['Monthly', '6 Month', '12 Month']

df[['contract_type_encoded', 'contract_type_label']].drop_duplicates().sort_values('contract_type_encoded')

```

```

:
  contract_type_encoded  contract_type_label
2                     0             Monthly
0                     1             6 Month
4                     2             12 Month

```

c. Rekonstruksi Nama Kota

Informasi kota tersimpan dalam format one-hot encoding (**city_Faisalabad**, **city_Lahore**, **dst.**). Kolom-kolom tersebut direkonstruksi menjadi satu variabel kategorikal **city_name** menggunakan fungsi **idxmax()**.

```

city_columns = [col for col in df.columns if col.startswith('city_')]
df['city_name'] = df[city_columns].idxmax(axis=1).str.replace('city_', '')

df[['city_name']].value_counts()

```

3.6.2.2 Pembentukan Dataset Populasi Churn

Untuk keperluan analisis diagnostik, dibentuk subset **df_churn** yang hanya berisi pelanggan dengan **churn_status = 1**. Pendekatan ini dipilih karena tujuan analisis bukan membandingkan dua kelompok, melainkan memprofilkan karakteristik populasi churn secara spesifik.

```

city_columns = [col for col in df.columns if col.startswith('city_')]
df['city_name'] = df[city_columns].idxmax(axis=1).str.replace('city_', '')

df[['city_name']].value_counts()

```

Subset ini digunakan pada seluruh analisis statistik deskriptif, distribusi variabel, analisis multivariat, validasi outlier, dan analisis korelasi. Pengecualian berlaku pada analisis konfirmatif (Subbab 3.6.5) yang secara eksplisit membutuhkan kedua kelompok.

3.6.2.3 Statistik Deskriptif

Statistik deskriptif dihitung menggunakan fungsi **describe()** dari library pandas, dilengkapi dengan tabel ringkasan mean, median, dan modus untuk tiga variabel numerik utama: **support_tickets_capped**, **contract_type_encoded**, dan **monthly_bill_capped**.

```
key_vars = ['support_tickets_capped', 'contract_type_encoded', 'monthly_bill_capped']

print("Statistik Deskriptif Variabel Numerik Kunci (khusus populasi churn):")
display(df_churn[key_vars].describe())

profil = pd.DataFrame({
    'Mean': df_churn[key_vars].mean(),
    'Median': df_churn[key_vars].median(),
    'Modus': df_churn[key_vars].mode().iloc[0]
}).round(2)
```

Disini, variabel **feedback_category** tidak disertakan dalam perhitungan mean dan median karena bersifat nominal dimana nilai 0–3 hanya merepresentasikan kode kategori, bukan urutan atau tingkatan. Untuk variabel ini, hanya modus yang dihitung, sedangkan distribusi setiap kategori dianalisis secara terpisah melalui visualisasi.

3.6.2.4 Analisis Distribusi Variabel

Distribusi setiap variabel kunci pada populasi churn divisualisasikan menggunakan library seaborn dan matplotlib dengan gaya visual whitegrid yang diterapkan secara konsisten di seluruh notebook.

Variabel	Jenis Visualisasi	Alasan
support_tickets_capped	Histogram + KDE + Boxplot	Menampilkan distribusi dan sebaran nilai
contract_type_label	Countplot dengan anotasi persentase	Membandingkan frekuensi antar kategori
city_name	Horizontal barplot (top 10)	Menampilkan kota dengan churn terbanyak
feedback_category	Countplot dengan label kategori	Menampilkan proporsi setiap sentimen

3.6.2.5 Analisis Hubungan Churn

Analisis konfirmatif dilakukan menggunakan scatter plot dua variabel numerik sekaligus, dengan warna titik dibedakan berdasarkan **churn_status**. Pendekatan ini dipilih atas

rekomendasi dosen untuk menggantikan histogram/boxplot per kelompok, karena scatter plot memungkinkan pengamatan pola interaksi dua variabel secara bersamaan, bukan hanya sebaran satu variabel.

Pasangan variabel yang divisualisasikan antara lain:

- `tenure_months` vs `support_tickets_capped`
- `monthly_bill_capped` vs `support_tickets_capped`

```
plt.figure(figsize=(8, 6))
sns.scatterplot(
    data=df, x='tenure_months', y='support_tickets_capped',
    hue='churn_status', palette={0: '#2ecc71', 1: '#e74c3c'},
    alpha=0.6, s=45
)
```

3.6.2.7 Analisis Multivariat

Analisis multivariat dilakukan menggunakan pivot table dari pandas untuk mengevaluasi keterkaitan beberapa variabel secara bersamaan pada populasi churn. Pivot table memungkinkan pengamatan pola gabungan yang tidak terlihat pada analisis univariat.

Contoh pivot table yang digunakan:

```
pd.pivot_table(
    df_churn,
    values='support_tickets_capped',
    index='contract_type_label',
    columns='feedback_category',
    aggfunc='mean'
).round(2)
```

3.6.2.8 Validasi Outlier

Validasi outlier dilakukan menggunakan boxplot untuk mengidentifikasi nilai ekstrem pada variabel numerik kunci. Tujuannya adalah mengevaluasi apakah nilai ekstrem merupakan karakteristik data yang valid atau berpotensi memengaruhi interpretasi hasil analisis.

Perlu dicatat bahwa dataset telah melalui proses capping outlier pada Notebook D, sehingga nilai ekstrem yang tersisa pada tahap ini merupakan nilai yang memang ada dalam rentang yang telah ditentukan sebelumnya.

3.6.2.9 Analisis Korelasi

Analisis korelasi dilakukan menggunakan heatmap korelasi dari seaborn untuk mengevaluasi hubungan antarvariabel kualitas layanan pada populasi churn. Koefisien korelasi Pearson digunakan sebagai ukuran kekuatan hubungan.

```
fokus_kolom = ['churn_status', 'support_tickets_capped', 'contract_type_encoded',  
              'feedback_category', 'monthly_bill_capped', 'tenure_months',  
              'count_poor', 'count_unreliable', 'count_slow', 'count_expensive', 'count_support']  
  
corr_fokus = df[fokus_kolom].corr()  
  
plt.figure(figsize=(9, 7))  
sns.heatmap(corr_fokus, annot=True, fmt='.2f', cmap='coolwarm', center=0, linewidths=.5)  
plt.title('Matriks Korelasi Variabel Kualitas Layanan')  
plt.tight_layout()  
plt.show()
```

3.6.3 Analisis Finansial dan Sensitivitas Harga

3.6.3.1 Analisis Komparatif Sebaran Bill-to-Income Ratio

Untuk mengetahui rasio antara tagihan bulanan dan pendapatan pelanggan, dibuat kolom `bill_to_income_ratio`. Untuk mencegah pembagian dengan nol, nilai 0.1 ditambahkan ke penyebut.

```
import numpy as np  
  
df['bill_to_income_ratio'] = (  
    df['monthly_bill_capped'] /  
    (df['monthly_income_scaled'] + 0.1)  
)
```

Agar visualisasi tidak menghasilkan error, nilai tak hingga (infinite) diubah menjadi NaN. Selanjutnya, baris pada kolom `bill_to_income_ratio` yang memiliki nilai kosong dihapus. Visualisasi menggunakan Histogram dengan kurva Kernel Density Estimation (KDE) untuk membandingkan distribusi Bill-to-Income Ratio antara pelanggan churn dan non-churn.

3.6.3.2 Analisis Komparatif Nominal Tagihan Bulanan

Analisis ini bertujuan untuk mengetahui apakah besarnya biaya layanan berkaitan dengan keputusan pelanggan untuk melakukan churn. Analisis dilakukan dengan membandingkan distribusi nominal tagihan bulanan antara pelanggan churn dan non-churn menggunakan histogram.

```
plt.figure(figsize=(10,5))

sns.histplot(
    data=df,
    x='monthly_bill_capped',
    hue='churn',
    kde=True,
    bins=30,
    multiple='dodge'
)
```

3.6.3.3 Analisis Komparatif Pendapatan Bulanan

Tujuan analisis ini adalah untuk membandingkan distribusi pendapatan pelanggan berdasarkan status churn untuk menentukan apakah keputusan pelanggan untuk terus menggunakan layanan terkait dengan kemampuan finansial mereka. Visualisasi dilakukan menggunakan Histogram untuk membandingkan distribusi pendapatan pelanggan churn dan non-churn, sehingga pola perbedaan kemampuan finansial antar kedua kelompok dapat diamati dengan lebih jelas.

```
plt.figure(figsize=(10,5))

sns.histplot(
    data=df,
    x='monthly_income_scaled',
    hue='churn',
    palette={
        0: 'royalblue',
        1: 'darkorange'
    },
    bins=30,
    kde=True,
    multiple='dodge'
)
```

3.6.3.4 Gambaran Variabel Financial Risk

Analisis ini memberikan gambaran awal mengenai distribusi financial_risk berdasarkan status churn. Visualisasi ini dilakukan untuk mengetahui bagaimana distribusi risiko finansial rendah dan tinggi pada kelompok pelanggan churn dan non-churn. Ini akan menjadi dasar analisis yang lebih mendalam. Visualisasi menggunakan count plot dari library seaborn untuk menampilkan jumlah pelanggan pada setiap kategori financial_risk. Grafik menunjukkan banyak pelanggan yang termasuk dalam semua kategori risiko keuangan, sehingga lebih mudah untuk melihat distribusi awal.

```
plt.figure(figsize=(8,5))

sns.countplot(
    data=df,
    x='financial_risk',
    hue='churn',
    palette={
        0:'royalblue',
        1:'darkorange'
    }
)
```

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Data Preprocessing

4.1.1. Hasil Setelah Preprocessing

Sebelum dilakukan pemrosesan, dataset mentah dievaluasi untuk mendeteksi permasalahan kualitas data seperti missing values, data duplikat, nilai tidak masuk akal (impossible values), inkonsistensi penulisan, dan keberadaan data pencilan (outlier). Berikut adalah rangkuman tindakan serta hasil setelah preprocessing dilakukan:

a. Penanganan Missing Values & Duplikat

Setelah melalui proses verifikasi, dipastikan tidak terdapat nilai yang hilang (missing values = 0) maupun baris data yang ganda (duplikat = 0) di dalam dataset final, sehingga integritas data tabular tetap terjaga.

b. Pembersihan Data Kategorikal

Dilakukan penghapusan spasi kosong (whitespace trimming) pada seluruh fitur kategorikal untuk mencegah redundansi kategori akibat kesalahan input teks.

c. Penanganan Outlier (Data Pencilan)

Fitur-fitur numerik utama seperti monthly_income, monthly_bill, internet_usage_gb, dan call_minutes diidentifikasi menggunakan metode Interquartile Range (IQR). Untuk meminimalkan bias akibat nilai ekstrem tanpa menghapus baris data, diterapkan metode pencatatan batas atas/bawah (capping atau Winsorization).

d. Transformasi Skala (Scaling)

Variabel numerik yang telah dibersihkan kemudian ditransformasikan menggunakan Min-Max Scaling guna menyamakan rentang nilai (domain skala 0 hingga 1), sehingga algoritma pemodelan dapat bekerja lebih optimal dan stabil tanpa terpengaruh oleh perbedaan satuan besaran fitur.

4.1.2 Perubahan Struktur Dataset (Kolom & Baris)

Proses transformasi data, encoding variabel kategorikal, serta ekstraksi fitur teks menyebabkan perubahan signifikan pada struktur dimensi dataset. Perubahan struktur ini dirangkum dalam tabel berikut:

Karakteristik Dimensi	Dataset Awal (Mentah)	Dataset Final (Hasil Preprocessing)	Keterangan Perubahan
Jumlah Baris	1,200 baris	1,200 baris	Jumlah baris tetap dipertahankan guna menjaga volume sampel eksperimen.
Jumlah Kolom	15 kolom	42 kolom	Mengalami

Karakteristik Dimensi	Dataset Awal (Mentah)	Dataset Final (Hasil Preprocessing)	Keterangan Perubahan
			penambahan sebanyak 27 kolom baru akibat <i>feature engineering</i> dan encoding.
Kolom Numerik	7 kolom	42 kolom	Seluruh kolom dalam dataset final telah berbentuk angka (int64 / float64).
Kolom Non-Numerik (Object/Text)	8 kolom	0 kolom	Semua fitur kategorikal dan teks bebas telah berhasil dikonversi sepenuhnya.

4.1.3 Rekayasa Fitur Baru (Feature Engineering)

Untuk memperkaya informasi perilaku pelanggan, dibentuk beberapa kelompok fitur baru yang diekstrak dari variabel demografi, keuangan, serta umpan balik pelanggan:

a. Fitur Berbasis Durasi dan Finansial

- **tenure_months:** Fitur ini dihitung berdasarkan selisih antara tanggal referensi analisis (25 Juni 2026) dengan tanggal registrasi pelanggan (signup_date). Fitur ini memberikan gambaran durasi loyalitas pelanggan dalam satuan bulan (berkisar antara 51 hingga 91 bulan).
- **financial_risk:** Fitur indikator biner (1 jika total tagihan bulanan monthly_bill lebih besar daripada pendapatan bulanan monthly_income, dan 0 jika sebaliknya). Fitur ini membantu mendeteksi risiko gagal bayar yang berpotensi memicu churn.

b. Fitur Indikator Anomali Perilaku

- **anomaly_pay_not_use:** Menandakan pelanggan yang membayar tagihan bulanan tinggi namun memiliki tingkat penggunaan internet atau menit panggilan yang sangat rendah.
- **anomaly_happy_leaver:** Menandakan segmen pelanggan khusus yang melakukan churn tanpa memberikan sinyal keluhan atau tiket dukungan (*support tickets* = 0) sebelumnya.
- **anomaly_genz_call_enthusiast:** Menandakan karakteristik unik dari kelompok usia muda (Gen-Z) yang memiliki durasi panggilan suara (*call minutes*) sangat tinggi di luar rata-rata kelompoknya.

c. Encoding Variabel Kategorikal

Variabel kategorikal nominal (seperti jenis kelamin, kota domisili, tingkat pendidikan, status pekerjaan, dan jenis kontrak) ditransformasikan menggunakan metode **One-Hot Encoding**. Proses ini menghasilkan kolom-kolom biner baru (seperti city_Hyderabad, city_Lahore, dsb.) sehingga dapat langsung diproses oleh algoritma klasifikasi.

d. Ekstraksi Fitur Teks (Text Preprocessing)

Kolom umpan balik bebas customer_feedback diekstrak menjadi fitur numerik menggunakan teknik binerisasi teks atau **Count Vectorizer** berbasis kata kunci spesifik untuk menangkap sentimen dan keluhan utama pelanggan, meliputi:

- **Masalah Biaya/Tagihan:** Berdasarkan kemunculan kata kunci seperti *'billing'*, *'expensive'*.
- **Masalah Jaringan/Sinyal:** Berdasarkan kemunculan kata kunci seperti *'poor'*, *'unreliable'*, *'drops'*, *'slow'*.
- **Layanan Customer Support:** Berdasarkan kemunculan kata kunci seperti *'support'*.
- **Sentimen Puas/Positif:** Berdasarkan kemunculan kata kunci seperti *'happy'*, *'satisfied'*, *'good'*.

4.1.4 Karakteristik Dataset Final


Dataset final yang dihasilkan memiliki spesifikasi teknis sebagai berikut:

- **Ukuran Matriks Data:** 1,200 baris $\times$ 42 kolom.
- **Kebersihan Data:** 100% bersih dari nilai kosong, data duplikat, maupun teks mentah.
- **Kesiapan Model:** Seluruh data telah berformat numerik dan memiliki sebaran fitur yang stabil setelah proses pembatasan outlier (*capping*), meminimalkan risiko bias saat model melakukan proses training.

Dengan struktur data yang komprehensif ini, dataset siap didistribusikan ke dalam analisis lanjutan pada masing-masing sub-tim (Analisis Demografi, Analisis Penggunaan Layanan, dan Pemodelan Klasifikasi Prediktif Churn).

4.2 Hasil General EDA

- **Evaluasi Distribusi Proporsi Target Churn**




Gambar 4.2.1 Distribusi Proporsi Variabel Target Churn

Berdasarkan visualisasi frekuensi variabel target, didapatkan rasio pembagian kelas sebesar 65% untuk kelas pelanggan aktif bertahan (Retained / 0) dan 35% untuk kelas pelanggan keluar (Churn / 1). Distribusi ini menandakan bahwa dataset berada dalam kondisi ketidakseimbangan kelas tingkat ringan (mildly imbalanced). Implikasinya,

model machine learning klasifikasi biner nantinya dapat dilatih secara langsung tanpa keharusan manipulasi sintetik radikal seperti aplikasi algoritma SMOTE, namun proses pengujian harus tetap menggunakan metrik evaluasi yang sensitif (seperti F1-Score atau AUC-ROC) alih-alih murni mengandalkan metrik akurasi umum.


- **Identifikasi Hubungan Awal & Skewness**



Gambar 4.2.2 Analisis Visual Hubungan Atribut Kunci terhadap Churn Rate

Analisis visual melalui visualisasi sebaran histogram membuktikan bahwa rekayasa pembatasan nilai (*capping outlier*) berhasil mereduksi deviasi ekstrim sebaran data tanpa merusak bentuk alami distribusi populasi sampel. Hubungan awal menunjukkan adanya kecenderungan korelasi linear positif antara tingginya frekuensi keluhan pada fitur *support_tickets* dengan kecenderungan nilai target churn.

- **Uji Multikolinieritas Melalui Matriks Korelasi**



Gambar 4.2.3 Heatmap Matriks Korelasi Antar Variabel Pasca-Preprocessing

Evaluasi koefisien matriks korelasi linier antar variabel numerik pasca-preprocessing dijalankan secara menyeluruh. Pengujian ini memastikan tidak terdapat pasangan variabel independen yang memiliki korelasi linear terlalu tinggi (multikolinieritas ekstrem), sehingga menjamin stabilitas estimasi parameter bobot pada tahapan pemodelan prediktif klasifikasi selanjutnya. Rangkaian temuan umum dari EDA ini memberikan pondasi data yang kokoh bagi tim pengerjaan sub-analisis berikutnya.

4.3 Hasil Analisis Customer Segmentation


Segmentasi pelanggan (Customer Segmentation) dilakukan untuk memetakan perilaku penggunaan layanan dan dampaknya terhadap tingkat churn. Analisis ini difokuskan pada tiga variabel numerik utama yang telah melalui proses penanganan outlier (Winsorization/Capping), yaitu `internet_usage_gb_capped`, `call_minutes_capped`, dan `monthly_bill_capped`.

4.3.1 Segmentasi Pelanggan Berdasarkan K-Means Clustering

...	Avg_Internet_GB	Avg_Call_Minutes	Avg_Monthly_Bill	Churn_Rate	Total_Customers
Persona					
Segmen 0	13.89	135.29	4828.89	34.0	602
Segmen 1	18.90	186.36	14950.54	57.0	121
Segmen 2	16.67	349.12	5254.60	33.0	199
Segmen 3	36.76	165.20	4911.18	29.0	278

Berdasarkan hasil segmentasi menggunakan algoritma K-Means, pola perilaku pelanggan terbagi menjadi 4 kelompok dengan karakteristik sebagai berikut:

1. **Segmen 0 (Casual User):** Kelompok mayoritas (602 pelanggan) dengan pemakaian rata-rata yang standar; internet 13.89 GB dan durasi telepon 135 menit. Tagihan bulannya pun wajar di angka Rp 4.828.
2. **Segmen 1 (High-Paying Victims):** Segmen ini memiliki tingkat pemakaian menengah (Internet 18.90 GB, Telepon 186 menit), TETAPI menanggung rata-rata tagihan bulanan tertinggi yang meledak di angka Rp 14.950 (hampir 3x lipat segmen lain). Kondisi inefisiensi harga (wasted value) ini berpotensi memicu ketidakpuasan ekstrem.
3. **Segmen 2 (Traditional Communicator):** Segmen yang didominasi pengguna layanan suara dengan durasi telepon tertinggi (rata-rata 349 menit), namun pemakaian data internet cenderung rendah (16.67 GB). Tagihannya wajar di angka Rp 5.254.
4. **Segmen 3 (Digital Native / Internet Enthusiast):** Segmen dengan kebutuhan data masif, di mana konsumsi internet rata-rata mencapai 36.76 GB, namun tagihannya tetap ekonomis (Rp 4.911).



Analisis Risiko Churn: Berdasarkan visualisasi persentase tingkat churn tiap segmen, terbukti bahwa faktor finansial (tagihan bulanan) sangat memengaruhi loyalitas pelanggan:

- Risiko Kritis: Segmen 1 (High-Paying Victims) menyumbang tingkat churn tertinggi secara masif hingga mencapai 57%. Hal ini membuktikan bahwa pelanggan yang mengalami anomali tagihan mahal padahal pemakaiannya standar akan merasa dirugikan secara finansial dan cenderung segera menghentikan langganannya.
- Segmen Teraman: Segmen 3 (Digital Native) adalah segmen paling loyal dengan tingkat churn paling rendah (29%). Mereka sangat diuntungkan karena mendapatkan kuota internet melimpah ruah dengan harga yang murah meriah.

4.4 Hasil Analisis Service Quality

Subbab ini menyajikan hasil analisis **Service Quality** yang bertujuan mengidentifikasi faktor-faktor kualitas layanan dan *pain points* yang berkontribusi terhadap terjadinya *customer churn*. Analisis difokuskan pada beberapa variabel utama, yaitu **support_tickets**, **contract_type**, **city**, dan **customer_feedback**, untuk memperoleh pemahaman yang lebih mendalam mengenai karakteristik pelanggan yang memutuskan berhenti menggunakan layanan perusahaan.

Sebagian besar pembahasan dilakukan menggunakan subset data yang terdiri atas **420 pelanggan churn** atau **35% dari total 1.200 pelanggan**, sehingga hasil yang diperoleh dapat menggambarkan karakteristik dan pola layanan pada populasi pelanggan yang benar-benar mengalami churn. Pendekatan ini dipilih agar faktor-faktor yang berkaitan dengan kualitas

layanan dapat dianalisis secara lebih spesifik tanpa dipengaruhi oleh karakteristik pelanggan yang masih bertahan.

Pengecualian dilakukan pada analisis hubungan antara variabel dengan status churn pada Subbab 4.4.4, yang menggunakan seluruh dataset. Hal tersebut bertujuan untuk membandingkan karakteristik pelanggan churn dan non-churn sehingga hubungan setiap variabel terhadap kemungkinan terjadinya churn dapat diamati secara lebih komprehensif.

4.4.1 Persiapan Dataset

Rename Kolom Target

```
print("Kolom 'churn' berhasil diganti nama menjadi 'churn_status'.")  
Kolom 'churn' berhasil diganti nama menjadi 'churn_status'.
```

Pembuatan Label jJenis Kontrak

```
Out[6]:  
   contract_type_encoded  contract_type_label  
2                      0      Monthly  
0                      1      6 Month  
4                      2      12 Month
```

Rekonstruksi Nama Kota

```

Out[7]:
city_name
Quetta      119
Rawalpindi  116
Gujranwala  115
Multan      113
Sialkot     113
Peshawar    108
Lahore      108
Hyderabad   107
Faisalabad  103
Karachi     100
Islamabad   98
Name: count, dtype: int64

```

Membentuk Subset Data Pelanggan Churn

```

print(f"Jumlah total pelanggan : {n_total}")
print(f"Jumlah pelanggan churn : {n_churn}")
print(f"Proporsi churn : {n_churn / n_total:.1%}")

Jumlah total pelanggan : 1200
Jumlah pelanggan churn : 420
Proporsi churn : 35.0%

```

Berdasarkan proses persiapan dataset yang telah dilakukan, seluruh penyesuaian data berhasil diterapkan sehingga dataset siap digunakan pada tahap analisis berikutnya. Variabel target telah memiliki penamaan yang lebih konsisten, jenis kontrak berhasil dikonversi ke dalam label kategorikal yang lebih mudah diinterpretasikan, serta informasi kota yang sebelumnya berbentuk **one-hot encoding** berhasil direkonstruksi menjadi satu variabel kategorikal, yaitu **city_name**, yang mencakup 11 kota.

Selanjutnya, dibentuk subset **df_churn** yang terdiri atas **420 pelanggan** atau **35% dari total populasi pelanggan**. Jumlah tersebut sesuai dengan proporsi pelanggan yang mengalami churn pada hasil General EDA, sehingga subset ini dinilai representatif untuk menggambarkan karakteristik pelanggan yang berhenti menggunakan layanan. Dataset inilah yang kemudian digunakan sebagai dasar pada analisis statistik deskriptif, distribusi variabel, analisis multivariat, validasi outlier, dan analisis korelasi pada subbab berikutnya.

4.4.2 Statistik Deskriptif

Statistik Deskriptif Variabel Numerik

Statistik Deskriptif Variabel Numerik Kunci (khusus populasi churn):			
	support_tickets_capped	contract_type_encoded	monthly_bill_capped
count	420.000000	420.000000	420.000000
mean	2.114286	0.440476	6524.313690
std	1.052913	0.733631	3601.822682
min	0.000000	0.000000	1116.000000
25%	1.000000	0.000000	3651.500000
50%	2.000000	0.000000	5616.500000
75%	3.000000	1.000000	8676.250000
max	5.000000	2.000000	13776.125000

Ringkasan Mean, Median, dan Modus			
	Mean	Median	Modus
support_tickets_capped	2.11	2.0	2.00
contract_type_encoded	0.44	0.0	0.00
monthly_bill_capped	6524.31	5616.5	13776.12
Modus feedback_category (populasi churn): 1 -> Jaringan/Sinyal (Mean/median sengaja tidak ditampilkan karena feedback_category bersifat nomina 1)			

Berdasarkan hasil statistik deskriptif pada populasi pelanggan yang mengalami *churn*, diperoleh beberapa karakteristik sebagai berikut.

1. Support Tickets

Variabel ***support_tickets_capped*** memiliki rata-rata sebesar **2,11** tiket per pelanggan, dengan median **2,00** dan modus **2**. Hasil ini menunjukkan bahwa sebagian besar pelanggan yang mengalami *churn* telah menghubungi layanan pelanggan sekitar dua kali sebelum memutuskan berhenti menggunakan layanan. Temuan ini memberikan indikasi awal bahwa permasalahan layanan telah dialami pelanggan sebelum terjadinya *churn*.

2. Jenis Kontrak

Variabel ***contract_type_encoded*** memiliki nilai modus pada kategori **0 (Monthly)**. Hal ini menunjukkan bahwa kontrak bulanan merupakan jenis kontrak yang paling banyak dimiliki oleh pelanggan yang mengalami *churn*. Temuan ini mengindikasikan bahwa pelanggan dengan kontrak bulanan lebih mendominasi populasi *churn*, meskipun hubungan antara jenis kontrak dan *churn* akan dibahas lebih lanjut pada analisis berikutnya.

3. Tagihan Bulanan


Variabel ***monthly_bill_capped*** memiliki rata-rata sebesar **Rp6.524**, dengan rentang nilai antara **Rp1.116 hingga Rp13.776**. Rentang nilai yang cukup lebar menunjukkan bahwa pelanggan yang mengalami *churn* berasal dari berbagai tingkat pengeluaran. Dengan demikian, keputusan pelanggan untuk berhenti menggunakan layanan tidak hanya terjadi pada kelompok pelanggan dengan tagihan tertentu.

4. Kategori Feedback (Dibahas pada Bagian 7)

Variabel ***feedback_category*** memiliki nilai modus pada kategori **1 (Jaringan/Sinyal)**. Hal ini menunjukkan bahwa keluhan terkait kualitas jaringan merupakan jenis umpan balik yang paling sering disampaikan oleh pelanggan yang mengalami *churn*. Temuan ini memberikan indikasi awal bahwa kualitas jaringan menjadi salah satu *pain point* utama yang perlu menjadi perhatian perusahaan.

4.4.3 Distribusi Variabel pada Populasi Churn


Support Tickets (*support_tickets_capped*)



Distribusi **support tickets** pada populasi pelanggan yang mengalami *churn* didominasi oleh pelanggan yang memiliki **1–3 tiket keluhan** sebelum berhenti menggunakan layanan. Nilai median sebesar **2** menunjukkan bahwa sebagian besar pelanggan telah berinteraksi dengan layanan pelanggan lebih dari satu kali selama masa berlangganan.

Sebaran data juga memperlihatkan adanya sejumlah pelanggan dengan jumlah tiket yang lebih tinggi, meskipun jumlahnya relatif sedikit. Kondisi ini mengindikasikan bahwa frekuensi keluhan merupakan salah satu karakteristik yang cukup umum ditemukan pada pelanggan yang mengalami *churn*, sehingga dapat menjadi sinyal awal bagi perusahaan dalam mengidentifikasi pelanggan yang berisiko berhenti menggunakan layanan.


Jenis Kontrak (**contract_type**)



Komposisi jenis kontrak pada populasi pelanggan yang mengalami *churn* didominasi oleh kontrak **Monthly**, dengan proporsi sekitar **70%** dari keseluruhan pelanggan churn. Sementara itu, pelanggan dengan kontrak **6 bulan** dan **12 bulan** memiliki proporsi yang relatif lebih kecil.

Dominasi kontrak bulanan menunjukkan bahwa sebagian besar pelanggan yang berhenti menggunakan layanan tidak terikat oleh kontrak jangka panjang. Fleksibilitas kontrak bulanan memungkinkan pelanggan untuk mengakhiri layanan dengan lebih mudah ketika merasa layanan yang diterima tidak sesuai dengan harapan. Meskipun demikian, hubungan antara jenis kontrak dan kecenderungan *churn* akan dibahas lebih lanjut pada analisis hubungan variabel terhadap status *churn* pada subbab berikutnya.


Distribusi Kota (city_name)



Distribusi pelanggan **churn** berdasarkan kota menunjukkan bahwa **Lahore, Peshawar, dan Gujranwala** merupakan tiga kota dengan jumlah pelanggan **churn** tertinggi. Temuan ini sejalan dengan hasil General EDA yang menunjukkan bahwa pelanggan **churn** tidak tersebar secara merata di seluruh wilayah.

Konsentrasi pelanggan **churn** pada beberapa kota tertentu mengindikasikan adanya perbedaan karakteristik antarwilayah yang berpotensi memengaruhi pengalaman pelanggan. Perbedaan tersebut dapat berkaitan dengan kualitas layanan, kondisi infrastruktur jaringan, maupun karakteristik pelanggan di masing-masing wilayah. Oleh karena itu, kota-kota dengan jumlah **churn** yang tinggi dapat menjadi prioritas bagi perusahaan untuk melakukan evaluasi dan investigasi lebih lanjut terhadap faktor-faktor yang memengaruhi keputusan pelanggan untuk berhenti menggunakan layanan.

Kategori Feedback (feedback_category)



Distribusi **kategori feedback** menunjukkan bahwa keluhan terkait **Jaringan/Sinyal** merupakan jenis umpan balik yang paling banyak disampaikan oleh pelanggan yang mengalami *churn*. Selanjutnya, kategori **Biaya/Tagihan** dan **Customer Support** juga memiliki proporsi yang cukup besar, menunjukkan bahwa ketiga aspek tersebut menjadi keluhan utama yang dirasakan pelanggan sebelum memutuskan berhenti menggunakan layanan.


Di sisi lain, hanya sebagian kecil pelanggan *churn* yang memberikan umpan balik dalam kategori **Positif/Puas**. Temuan ini menunjukkan bahwa terdapat pelanggan yang tetap memutuskan berhenti menggunakan layanan meskipun tidak menyampaikan keluhan secara eksplisit melalui *feedback*. Kondisi tersebut dapat menjadi indikasi awal adanya fenomena *happy leaver*, yang memerlukan analisis lebih lanjut untuk memahami faktor-faktor lain yang memengaruhi keputusan pelanggan melakukan *churn*.

4.4.4 Analisis Hubungan Dengan Churn

Setelah karakteristik pelanggan yang mengalami *churn* dianalisis pada subbab sebelumnya, tahap berikutnya adalah membandingkan karakteristik pelanggan *churn* dan *non-churn* untuk melihat hubungan setiap variabel terhadap status *churn*. Berbeda dengan analisis sebelumnya yang hanya berfokus pada populasi pelanggan *churn*, analisis pada subbab ini menggunakan **seluruh dataset** yang terdiri atas **1.200 pelanggan**, sehingga perbedaan pola antar kedua kelompok dapat diamati secara lebih komprehensif.

Hubungan tersebut divisualisasikan menggunakan **scatter plot** untuk memberikan gambaran mengenai pola penyebaran setiap variabel terhadap status *churn*. Melalui pendekatan ini, dapat diidentifikasi apakah suatu variabel menunjukkan kecenderungan tertentu yang membedakan pelanggan yang bertahan dengan pelanggan yang memutuskan berhenti menggunakan layanan.


Support Tickets (support_tickets_capped) vs Tenure Months (tenure_months)



Scatter plot menunjukkan bahwa pelanggan *churn* (merah) cenderung terkonsentrasi pada rentang **2–5 support tickets**, sedangkan pelanggan *non-churn* (hijau) tersebar lebih merata pada berbagai jumlah keluhan. Pola ini menunjukkan bahwa pelanggan yang lebih sering mengajukan keluhan memiliki kecenderungan lebih tinggi untuk mengalami *churn*.

Sebaliknya, masa berlangganan (*tenure months*) tidak memperlihatkan pola yang jelas terhadap status *churn*. Hal ini mengindikasikan bahwa frekuensi keluhan lebih berasosiasi dengan *churn* dibandingkan lamanya pelanggan menggunakan layanan.

Support Tickets (`support_tickets_capped`) vs Monthly Bill (`monthly_bill_capped`)



Scatter plot menunjukkan bahwa pelanggan *churn* tersebar pada berbagai rentang **monthly bill**, sehingga tidak terlihat pola *churn* yang terkonsentrasi pada tingkat tagihan tertentu. Sebaliknya, pelanggan dengan **support tickets** yang lebih tinggi cenderung didominasi oleh pelanggan *churn*.

Temuan ini menunjukkan bahwa **support tickets** memiliki hubungan yang lebih kuat dengan status *churn* dibandingkan **monthly bill**, sehingga frekuensi keluhan menjadi indikator yang lebih relevan dalam mengidentifikasi pelanggan yang berisiko melakukan *churn*.

4.4.5 Analisis Multivariat

Sebaran Jenis Kontrak Berdasarkan Kota

Out[17]:

contract_type_label	Monthly	6 Month	12 Month	Total
city_name				
Lahore	35	6	3	44
Gujranwala	31	6	6	43
Quetta	27	9	6	42
Peshawar	34	4	3	41
Sialkot	27	8	6	41
Hyderabad	28	1	11	40
Rawalpindi	22	10	6	38
Islamabad	26	8	2	36
Multan	20	6	8	34
Karachi	21	3	8	32
Faisalabad	25	2	2	29

Rata-rata Support Tickets per Jenis Kontrak

support_tickets_capped	
contract_type_label	
Monthly	1.81
6 Month	2.97
12 Month	2.72

Kategori Feedback per Jenis Kontrak

Out[19]:

feedback_label	Biaya/Tagihan	Customer Support	Jaringan/Sinyal	Positif/Puas
contract_type_label				
Monthly	20.3	9.5	41.6	28.7
6 Month	19.0	7.9	44.4	28.6
12 Month	23.0	6.6	42.6	27.9

Berdasarkan hasil **pivot table**, diperoleh beberapa temuan sebagai berikut.

1. **Kontrak Monthly dengan feedback Jaringan/Sinyal memiliki rata-rata support tickets tertinggi.**

Temuan ini menunjukkan bahwa pelanggan dengan kontrak bulanan yang mengalami kendala jaringan cenderung lebih sering menghubungi layanan pelanggan dibandingkan kelompok lainnya.


2. **Pelanggan dengan kontrak 12 Month memiliki rata-rata support tickets yang lebih rendah pada seluruh kategori feedback.**

Hal ini mengindikasikan bahwa pelanggan dengan kontrak jangka panjang cenderung lebih jarang menyampaikan keluhan, terlepas dari kategori feedback yang diberikan.

3. **Jenis kontrak dan kategori feedback menunjukkan pola yang berbeda terhadap intensitas support tickets.**

Pelanggan dengan kontrak **Monthly** dan feedback negatif cenderung memiliki frekuensi keluhan yang lebih tinggi dibandingkan pelanggan dengan kontrak jangka panjang, sehingga kedua variabel tersebut dapat menjadi indikator penting dalam memahami karakteristik pelanggan yang berisiko mengalami *churn*.


4.4.6 Validasi Outlier



Hasil validasi menunjukkan bahwa tidak terdapat lagi nilai ekstrem yang berada di luar batas wajar pada seluruh variabel yang dianalisis. Hal ini menunjukkan bahwa proses *capping outlier* pada tahap *preprocessing* berhasil mengurangi pengaruh nilai ekstrem tanpa menghilangkan karakteristik utama data.

Dengan demikian, distribusi data dinilai telah memadai untuk digunakan pada analisis selanjutnya karena tidak lagi dipengaruhi oleh *outlier* yang berpotensi mendistorsi hasil analisis.

4.4.7 Analisis Korelasi



Berdasarkan hasil **heatmap korelasi**, diperoleh beberapa temuan sebagai berikut.

1. **Support tickets berkorelasi positif dengan count_poor, count_drops, dan count_slow.**
Hal ini menunjukkan bahwa semakin banyak **support tickets** yang diajukan pelanggan, semakin tinggi pula kecenderungan pelanggan memberikan umpan balik terkait kualitas layanan yang buruk, seperti jaringan lambat, sering terputus, atau kualitas layanan yang kurang memuaskan.
2. **Count_expensive berkorelasi positif dengan monthly bill.**
Temuan ini menunjukkan bahwa pelanggan dengan **monthly bill** yang lebih tinggi cenderung lebih sering memberikan keluhan terkait biaya layanan, sehingga hubungan tersebut selaras dengan karakteristik data yang diamati.
3. **Tidak ditemukan korelasi yang sangat tinggi antarvariabel kualitas layanan.**
Nilai korelasi yang relatif rendah hingga sedang menunjukkan bahwa setiap variabel masih merepresentasikan aspek kualitas layanan yang berbeda, sehingga tidak terdapat indikasi multikolinearitas yang dapat mempengaruhi hasil analisis.

4.4.8 Ringkasan Insight dan Rekomendasi

Hasil analisis **Service Quality** menunjukkan tiga insight utama yang menggambarkan karakteristik pelanggan yang mengalami *churn*, yaitu sebagai berikut.

1. **Keluhan berulang sebagai sinyal churn**

Pelanggan yang mengalami *churn* memiliki rata-rata **2,11 support tickets**, dengan distribusi yang cenderung berada pada nilai yang lebih tinggi. Temuan ini menunjukkan bahwa akumulasi keluhan, bukan sekadar keluhan tunggal, berkaitan dengan meningkatnya kecenderungan pelanggan untuk melakukan *churn*.

2. **Kontrak Monthly sebagai faktor risiko**

Sekitar **70%** pelanggan *churn* memiliki kontrak **Monthly**. Fleksibilitas kontrak jangka pendek memungkinkan pelanggan menghentikan layanan dengan lebih mudah ketika mengalami ketidakpuasan dibandingkan pelanggan yang terikat kontrak jangka panjang.

3. **Jaringan/Sinyal sebagai *pain point* utama**

Kategori feedback **Jaringan/Sinyal** menjadi keluhan yang paling dominan pada populasi pelanggan *churn*. Temuan ini diperkuat oleh korelasi positif antara **support tickets** dengan variabel **count_drops** dan **count_slow**, yang menunjukkan bahwa permasalahan kualitas jaringan berkaitan dengan meningkatnya frekuensi keluhan pelanggan.

4.4.9 Rekomendasi Bisnis

Temuan yang diperoleh dari analisis **Service Quality** memberikan beberapa rekomendasi strategis yang dapat dipertimbangkan perusahaan untuk meningkatkan kualitas layanan sekaligus menekan tingkat *customer churn*, yaitu sebagai berikut.

1. **Prioritaskan perbaikan kualitas jaringan di kota dengan tingkat churn tinggi**

Kota **Lahore, Peshawar, dan Gujranwala** memiliki jumlah pelanggan *churn* tertinggi. Oleh karena itu, peningkatan kualitas infrastruktur dan stabilitas jaringan di wilayah tersebut dapat menjadi prioritas, mengingat keluhan terkait **Jaringan/Sinyal** merupakan kategori *feedback* yang paling dominan.

2. **Implementasikan program retensi berbasis support tickets**

Pelanggan yang telah mengajukan ≥ 2 **support tickets** dapat diprioritaskan dalam program retensi proaktif, seperti pemberian kompensasi, peningkatan kualitas layanan, atau tindak lanjut langsung dari tim *customer service*. Pendekatan ini diharapkan mampu mengurangi risiko pelanggan berhenti menggunakan layanan.

3. **Dorong migrasi dari kontrak Monthly ke kontrak jangka panjang**

Sebagian besar pelanggan *churn* menggunakan kontrak **Monthly**. Oleh karena itu, perusahaan dapat menawarkan insentif, seperti potongan harga atau bonus layanan, untuk mendorong pelanggan beralih ke kontrak **6 Month** atau **12 Month**, sehingga meningkatkan komitmen pelanggan terhadap layanan.

4. **Tingkatkan transparansi terkait biaya layanan**


Keluhan mengenai **Biaya/Tagihan** merupakan kategori *feedback* terbanyak kedua

setelah **Jaringan/Sinyal**. Perusahaan dapat meningkatkan transparansi melalui rincian tagihan yang lebih jelas, notifikasi penggunaan secara *real-time*, atau penyediaan paket layanan yang lebih fleksibel agar pelanggan lebih memahami biaya yang dikenakan.

4.5 Hasil Analisis Financial Sensitivity

4.5.1 Analisis Komparatif Sensitivitas Harga dan Finansial Bill-to-Income Ratio


Penelitian menggunakan dataset `telecome_clean.csv`, yang telah melalui tahap preprocessing dan terdiri dari 1.200 data pelanggan dengan berbagai atribut yang terkait dengan karakteristik pelanggan, penggunaan layanan, kondisi keuangan, dan status churn. Dalam analisis ini, hanya variabel yang berkaitan dengan tujuan analisis sensitivitas harga dan finansial yang digunakan, yaitu: `monthly_bill_capped` `monthly_income_scaled` `bill_to_income_ratio` `financial_risk` `support_tickets_capped` `churn`.



Hasil analisis grafik tersebut menyebutkan bahwa pelanggan churn memiliki median yang lebih tinggi dibandingkan non-churn. Artinya yaitu beban finansial untuk pelanggan yang melakukan churn lebih tinggi dan menjadi lebih sensitif terhadap harga.


4.5.2 Analisis Komparatif Nominal Harga

Visualisasi menggunakan scatter plot yang menunjukkan pelanggan churn lebih banyak berfokus pada kelompok dengan pendapatan lebih rendah tetapi punya tagihan bulanan yang lebih tinggi jika dibandingkan dengan pelanggan yang memilih untuk tidak churn.




4.5.3 Hubungan Support Tickets dan Bill-to-Income Ratio

Scatter plot menunjukkan korelasi antara jumlah tiket bantuan dan rasio tagihan ke pendapatan berdasarkan status churn. Terlihat bahwa pelanggan dengan banyak keluhan dan rasio tagihan ke pendapatan yang tinggi berasal dari kelompok churn. Ini menunjukkan bahwa tidak hanya masalah keuangan tetapi juga kualitas layanan yang diterima oleh pelanggan mempengaruhi keputusan mereka untuk berhenti menggunakan layanan. Ketika pelanggan memiliki beban finansial yang besar dan sering mengalami kendala layanan, lebih mungkin mereka melakukan churn.




4.5.4 Analisis Korelasi Variabel Numerik terhadap Churn

Heatmap digunakan untuk melakukan analisis korelasi untuk mengetahui kekuatan hubungan antara masing-masing variabel numerik terhadap status churn. Hasil analisis menunjukkan bahwa dari semua variabel, variabel Ticket Support memiliki hubungan yang paling kuat dengan churn. Semakin sering pelanggan menghubungi layanan pelanggan untuk mengajukan keluhan, semakin besar kemungkinan mereka melakukan churn. Meskipun variabel Bill-to-Income Ratio tidak sekuat Support Tickets, ia juga menunjukkan hubungan positif terhadap churn. Sebaliknya, variabel Pendapatan Bulanan memiliki hubungan negatif terhadap churn, yang menunjukkan bahwa pelanggan yang lebih mampu cenderung menggunakan layanan. Secara keseluruhan, hasil korelasi menunjukkan bahwa kombinasi faktor finansial dan kualitas layanan mempengaruhi perilaku churn.




4.5.5 Analisis Proporsi Kasus Churn berdasarkan Financial Risk

Selain itu, penelitian ini mengevaluasi variabel risiko keuangan, yang berfungsi sebagai pengukur tingkat risiko keuangan pelanggan. Analisis dilakukan untuk mengetahui bagaimana risiko keuangan terdistribusi pada churn dan non-churn pelanggan. Grafik menunjukkan bahwa sebagian besar pelanggan berada pada kategori Financial Risk rendah. Namun demikian, proporsi pelanggan churn pada kelompok Financial Risk tinggi relatif lebih besar dibandingkan pelanggan non-churn.



4.5.6 Distribusi Bill-to-Income Ratio Berdasarkan Financial Risk

Analisis ini bertujuan untuk mengetahui bagaimana distribusi Bill-to-Income Ratio pada setiap kategori Financial Risk. Dengan membandingkan kedua variabel tersebut, dapat diamati apakah pelanggan yang memiliki risiko finansial tinggi juga cenderung memiliki beban tagihan yang lebih besar dibandingkan kemampuan finansialnya. Hasil visualisasi menunjukkan bahwa pelanggan dalam kategori risiko keuangan tinggi memiliki nilai Bill-to-Income Ratio yang cenderung lebih besar dibandingkan pelanggan dengan risiko keuangan rendah. Selain itu, distribusi pelanggan dalam kategori risiko keuangan tinggi lebih luas, yang menunjukkan bahwa ada perbedaan dalam tingkat beban keuangan pelanggan.



4.6 Insight Bisnis

Berdasarkan hasil analisis yang telah dilakukan dari tiga perspektif berbeda, yaitu segmentasi perilaku pelanggan (Notebook A), kualitas layanan dan pain points (Notebook B), serta sensitivitas harga dan kondisi finansial (Notebook C), diperoleh insight bisnis yang saling melengkapi dan memperkuat satu sama lain. Berikut adalah rangkuman insight utama dari masing-masing dimensi analisis.

4.6.1 Segmentasi Pelanggan Mengungkap Fenomena Wasted Value

Notebook A menerapkan algoritma K-Means Clustering dengan $K=4$ sebagai pengganti pendekatan kuadran berbasis median yang digunakan sebelumnya. Metode ini menghasilkan segmentasi yang lebih objektif karena pengelompokan ditentukan langsung oleh pola data, bukan oleh ambang batas yang ditetapkan secara manual. Elbow Method digunakan untuk menentukan nilai K optimal, dan hasil clustering berhasil mengidentifikasi empat persona pelanggan dengan karakteristik yang terdefinisi dengan jelas.

Temuan kritis dari segmentasi K-Means adalah teridentifikasinya **Segmen 1 (High-Paying Victims)**: pelanggan dengan penggunaan internet dan telepon yang hanya rata-rata (internet 18,90 GB, telepon 186 menit), namun menanggung tagihan bulanan yang anomali tinggi sebesar 14.950 atau hampir tiga kali lipat segmen lainnya. Ketidaksesuaian ekstrem antara nilai yang dibayarkan dengan nilai yang diterima (wasted value) ini secara langsung berkorelasi dengan churn rate tertinggi sebesar 57%.

Di sisi lain, **Segmen 3 (Digital Native)** terbukti sebagai segmen paling loyal dengan churn rate terendah sebesar 29%. Pelanggan pada segmen ini mendapatkan value tertinggi: konsumsi internet paling besar (rata-rata 36,76 GB) dengan tagihan yang tetap terjangkau (4.911). Pola ini mengonfirmasi bahwa kesesuaian antara paket dan kebutuhan nyata pelanggan adalah faktor penjaga loyalitas yang paling efektif.

Segmen 2 (Traditional Communicator) menjadi perhatian lain karena menyumbang churn rate mengkhawatirkan sebesar 39% dengan dominasi penggunaan layanan suara (rata-rata 349 menit/bulan). Sementara **Segmen 0 (Casual User)** adalah kelompok mayoritas (602 pelanggan) dengan pola penggunaan paling standar.

4.6.2 Frekuensi Keluhan dan Jenis Kontrak Sebagai Sinyal Churn Terukur

Notebook B menghasilkan gambaran pain points yang jauh lebih akurat dengan menggunakan subset *df_churn* berisi 420 pelanggan. Metodologi ini memisahkan dengan tegas antara analisis konfirmatif (menggunakan seluruh 1.200 data untuk membandingkan churn vs non-churn) dan analisis diagnostik (menggunakan hanya populasi churn untuk menggambarkan karakteristik pain points secara spesifik).

Temuan pertama dan paling konsisten: *support_tickets* merupakan variabel yang paling kuat membedakan pelanggan churn dan non-churn. Pelanggan yang churn rata-rata mengajukan 2,1 tiket keluhan, hampir tiga kali lipat pelanggan aktif (0,69 tiket). Analisis korelasi heatmap mengonfirmasi bahwa *support_tickets_capped* memiliki korelasi positif paling kuat terhadap *churn_status* dibandingkan seluruh variabel kualitas layanan lainnya yang dianalisis.

Temuan kedua: sekitar **70% pelanggan churn memiliki kontrak Monthly**, dan pola ini konsisten di seluruh 11 kota yang dianalisis, bukan anomali regional. Kontrak bulanan memberikan fleksibilitas keluar yang sangat tinggi sehingga hambatan untuk berhenti berlangganan menjadi sangat rendah.

Temuan ketiga dari analisis distribusi *feedback_category* pada populasi churn: **Jaringan/Sinyal merupakan pain point paling dominan ($\pm 42\%$)**, diikuti Positif/Puas (29%), Biaya/Tagihan (21%), dan Customer Support (9%). Temuan "Positif/Puas" sebesar 29% adalah penemuan kritis yang mengungkap fenomena *happy leaver*, pelanggan yang pergi tanpa menyampaikan keluhan eksplisit. Hal ini menandakan bahwa strategi retensi yang semata-mata berfokus pada penanganan keluhan hanya dapat menjangkau sekitar 71% kasus churn.

Secara geografis, Lahore, Peshawar, dan Gujranwala mencatat jumlah pelanggan churn absolut tertinggi, konsisten dengan pola yang ditemukan pada analisis awal General EDA.

4.6.3 Tekanan Finansial Bersifat Universal Lintas Demografi

Analisis Notebook C menghasilkan pemahaman penting, yaitu tekanan finansial yang mendorong churn tidak bersifat selektif terhadap kelompok demografi tertentu. Baik pelanggan berpendidikan rendah maupun doktoral, baik yang muda maupun yang tua, semuanya merasakan beban rasio tagihan yang setara ketika memutuskan untuk churn. Ini mengindikasikan bahwa internet telah berubah menjadi kebutuhan primer di era digital sehingga ketika harganya dirasakan tidak proporsional, seluruh segmen demografis akan bereaksi serupa.

Inflasi Pakistan sebesar 11,7% menjadi katalisator yang memperparah kondisi ini. Dua hubungan finansial kritis terkonfirmasi dari matriks korelasi: korelasi positif antara besaran tagihan dan rasio beban finansial (+0,17), serta korelasi negatif antara tingkat pendapatan dan rasio beban finansial (-0,28). Artinya, kenaikan tagihan sekecil apapun akan langsung dirasakan sebagai beban yang semakin berat, terutama oleh pelanggan berpendapatan rendah.

Konsentrasi risiko geografis terpusat di Karachi, Lahore, dan Faisalabad. Ketiga kota besar ini secara matematis terbukti memiliki akumulasi kasus *financial_risk* tertinggi, menjadikan mereka zona prioritas intervensi yang paling kritis.

4.6.4 Integrasi Insight: Efek Berlipat Antar Dimensi

Ketiga dimensi analisis tidak beroperasi secara terpisah. Terdapat efek berlipat (compounding effect) ketika lebih dari satu faktor risiko dialami secara bersamaan oleh pelanggan yang sama. Tabel berikut merangkum keterkaitan antardimensi tersebut.

Dimensi	Temuan Utama	Dampak terhadap Churn
Perilaku (A)	Segmen 1 (High-Paying Victims) membayar 3x lipat untuk pemakaian rata-rata; Segmen 3 (Digital Native)	Wasted value terkuantifikasi secara objektif melalui machine learning;

Dimensi	Temuan Utama	Dampak terhadap Churn
	paling loyal karena mendapat value tertinggi	anomali tagihan langsung memicu churn rate 57%
Layanan (B)	70% churn dari kontrak Monthly (konsisten di semua kota); Jaringan/Sinyal = 42% pain point; 29% happy leaver; support_tickets sebagai prediktor paling konsisten	Subset df_churn memberikan gambaran pain points yang lebih akurat; scatter plot mengonfirmasi pola interaksi dua variabel secara bersamaan
Finansial (C)	Beban finansial merata lintas demografi; korelasi tagihan (+0,17) dan pendapatan (-0,28) terhadap rasio beban; Karachi-Lahore-Faisalabad = klaster risiko tertinggi	Sensitivitas harga bersifat universal; intervensi geografis lebih cost-effective daripada strategi demografis massal
Integrasi (D)	Pelanggan Segmen 1 K-Means dengan kontrak Monthly, riwayat keluhan tinggi, di kota besar	Profil risiko churn kumulatif tertinggi, memerlukan intervensi retensi yang paling prioritas dan tersegmentasi

Terdapat keterkaitan lintas analisis yang signifikan: kota-kota dengan churn rate tinggi (temuan B) sekaligus merupakan kota dengan akumulasi risiko finansial tertinggi (temuan C). Pelanggan High-Paying Victims (temuan A) yang sudah merasa membayar lebih dari yang digunakan akan semakin cepat bereaksi ketika tekanan finansial meningkat (C), terutama jika juga memiliki riwayat keluhan tinggi (B).

4.7 Rekomendasi Bisnis

Berdasarkan seluruh insight yang telah diidentifikasi dari tiga dimensi analisis, berikut disajikan rekomendasi bisnis terintegrasi yang dirancang untuk menangani akar masalah churn secara menyeluruh. Setiap rekomendasi didukung oleh data kuantitatif yang ditemukan dalam proses analisis.

4.7.1 Rekomendasi Berdasarkan Analisis Segmentasi (Notebook A)

Permasalahan utama yang diidentifikasi adalah ketidaksesuaian antara paket layanan yang ditawarkan dengan kebutuhan nyata pelanggan, yang terkuantifikasi paling tajam melalui Segmen 1 (High-Paying Victims) dengan churn rate 57% dan tagihan anomali 14.950.

1. **Audit dan Pricing Adjustment Segmen 1 (High-Paying Victims).** Tim CRM harus segera mengidentifikasi dan menghubungi pelanggan yang masuk dalam Segmen 1 untuk menawarkan penyesuaian tarif (pricing adjustment) atau bundling paket yang lebih sesuai dengan pola pemakaian mereka. Tanpa intervensi langsung, segmen ini akan terus menjadi sumber churn terbesar karena akar masalahnya (wasted value) sudah terdefinisi dengan jelas.

2. **Peluncuran Paket Internet-Only untuk Segmen 3 (Digital Native).** Segmen ini sudah loyal (churn 29%) dan mendapatkan value tertinggi. Untuk mempertahankan loyalitas mereka sekaligus mendorong lebih banyak pelanggan ke segmen ini, perusahaan perlu meluncurkan paket data murni tanpa alokasi menit telepon yang tidak dibutuhkan. Paket ini menghilangkan unsur wasted value secara struktural.
3. **Strategi Upselling Sekunder untuk Segmen 3.** Alih-alih menaikkan harga dasar, tawarkan add-on opsional seperti speed booster, akses VPN premium, atau langganan streaming (Netflix/Spotify) untuk meningkatkan ARPU (Average Revenue Per User) dari segmen yang sudah stabil ini.
4. **Program Loyalitas Berbasis Penggunaan untuk Segmen 2 (Traditional Communicator).** Segmen ini memiliki churn 39% dengan dominasi penggunaan layanan suara. Program loyalitas yang memberikan bonus menit telepon, kualitas suara premium (HD Voice), atau prioritas jaringan untuk panggilan dapat menjadi diferensiator yang efektif untuk menurunkan tingkat churn pada segmen bernilai tinggi ini.

4.7.2 Rekomendasi Berdasarkan Analisis Kualitas Layanan (Notebook B)

Permasalahan utama yang diidentifikasi adalah tingginya frekuensi keluhan yang tidak ditangani secara proaktif, dominasi kontrak bulanan yang rentan churn, masalah kualitas jaringan sebagai pain point primer, dan adanya kelompok happy leaver yang tidak terdeteksi oleh pendekatan konvensional. Seluruh rekomendasi berikut didasarkan pada kuantifikasi data feedback pelanggan churn.

1. **Prioritas Utama: Audit dan Perbaikan Infrastruktur Jaringan (didukung ±42% feedback churn).** Karena Jaringan/Sinyal merupakan kategori keluhan paling dominan pada populasi churn, perbaikan infrastruktur jaringan merupakan intervensi dengan dampak retensi terluas. Lahore, Peshawar, dan Gujranwala harus menjadi wilayah prioritas audit jaringan karena ketiganya mencatat jumlah pelanggan churn absolut tertinggi.
2. **Implementasi Early Warning System (EWS) Berbasis Support Tickets.** Karena support_tickets merupakan prediktor churn paling konsisten (korelasi positif tertinggi terhadap churn_status), perusahaan perlu membangun sistem deteksi otomatis yang mengklasifikasikan pelanggan sebagai at-risk ketika mereka mengajukan tiket keluhan kedua atau lebih dalam satu periode tagihan. Tim retensi kemudian dapat melakukan intervensi proaktif sebelum pelanggan memutuskan untuk churn.
3. **Program Migrasi Kontrak Monthly → Jangka Panjang (didukung 70% data).** Tujuh puluh persen pelanggan churn berasal dari kontrak Monthly, dan pola ini konsisten di seluruh kota. Perusahaan dapat mempertimbangkan program migrasi dengan memberikan insentif seperti diskon biaya berlangganan, akses ke fitur atau kuota eksklusif, atau akumulasi poin loyalitas bagi pelanggan yang beralih ke kontrak 6 bulan atau 12 bulan. Migrasi kontrak secara langsung meningkatkan switching cost dan hambatan keluar pelanggan.
4. **Evaluasi Kelompok Happy Leaver melalui Exit Survey (menyasar 29% kasus churn).** Hampir sepertiga pelanggan churn memberikan feedback positif sebelum

berhenti. Kelompok ini tidak dapat diidentifikasi melalui data kualitas layanan konvensional, sehingga memerlukan pendekatan berbeda. Penambahan exit survey pada proses pembatalan layanan akan membantu mengidentifikasi faktor-faktor di luar kualitas layanan (penawaran kompetitor, perubahan kebutuhan, pertimbangan pribadi) yang belum tertangkap oleh data saat ini.

4.7.3 Rekomendasi Berdasarkan Analisis Finansial (Notebook C)

Permasalahan utama yang diidentifikasi adalah beban tagihan yang tinggi relatif terhadap pendapatan pelanggan, yang diperparah oleh tekanan inflasi makro, dengan konsentrasi risiko tertinggi di kota-kota besar Pakistan.

1. **Paket Retensi Fleksibel Berbasis Profil Finansial (Downgrade Program).** Mengembangkan mekanisme deteksi otomatis yang mengidentifikasi pelanggan dengan `bill_to_income_ratio` tinggi. Ketika sistem mendeteksi kondisi tersebut, perusahaan secara proaktif menawarkan opsi penurunan paket ke tarif yang lebih hemat sebelum pelanggan mengambil keputusan churn. Pendekatan proaktif ini jauh lebih efektif daripada menunggu pelanggan mengajukan permintaan sendiri.
2. **Skema Insentif Pembayaran Kontinu.** Mengimplementasikan program cashback otomatis sebesar 5-10% bekerja sama dengan platform dompet digital lokal Pakistan seperti Easypaisa atau JazzCash, bagi pelanggan yang membayar tagihan tepat waktu selama tiga bulan berturut-turut. Program ini tidak hanya meringankan beban psikologis biaya bulanan, tetapi juga menciptakan kebiasaan pembayaran yang konsisten dan meningkatkan ikatan pelanggan dengan layanan.
3. **Strategi Harga Regional Tersegmentasi.** Merancang tarif promo khusus, paket subsidi kuota, atau diskon bundle internet rumah tangga yang diprioritaskan untuk klaster kota berisiko tinggi: Karachi, Lahore, dan Faisalabad. Pendekatan regional ini jauh lebih cost-effective dibandingkan program massal tanpa segmentasi geografis, karena intervensi dilakukan langsung di wilayah dengan alarm bahaya churn finansial paling tinggi.

4.7.4 Matriks Strategi Retensi Terintegrasi

Seluruh rekomendasi di atas dapat diintegrasikan ke dalam kerangka strategi retensi bertingkat berdasarkan tingkat prioritas dan urgensi implementasi sebagaimana ditampilkan pada tabel berikut.

Prioritas	Inisiatif	Dimensi	Target Pelanggan
Tinggi	Audit infrastruktur jaringan + perbaikan wilayah prioritas	B	Lahore, Peshawar, Gujranwala (top 3 churn absolut)
Tinggi	Audit tagihan + pricing adjustment Segmen 1 K-Means	A	Pelanggan High-Paying Victims (churn rate 57%)
Tinggi	Early Warning System berbasis <code>support_tickets</code>	B	Pelanggan dengan ≥ 2 tiket keluhan dalam satu periode

Prioritas	Inisiatif	Dimensi	Target Pelanggan
Sedang	Program migrasi kontrak Monthly → Annual dengan insentif	B	70% pelanggan churn berkontrak Monthly
Sedang	Exit survey untuk kelompok Happy Leaver	B	29% pelanggan churn dengan feedback positif
Sedang	Downgrade program + insentif pembayaran berbasis profil finansial	C	Pelanggan dengan bill_to_income_ratio tinggi
Sedang	Strategi harga regional tersegmentasi	C	Karachi, Lahore, Faisalabad
Pemeliharaan	Paket internet-only + upselling Segmen 3 Digital Native	A	Pelanggan internet tinggi, churn rendah (29%)
Pemeliharaan	Program loyalitas berbasis menit telepon Segmen 2	A	Traditional Communicator (churn 39%)

BAB V

PENUTUP

5.1 Kesimpulan

Proyek analisis data Telecom Customer Churn telah berhasil melaksanakan seluruh tahapan yang direncanakan dari data preprocessing dan feature engineering hingga exploratory data analysis dari tiga perspektif yang berbeda, menghasilkan pemahaman komprehensif mengenai faktor-faktor yang mendorong pelanggan industri telekomunikasi Pakistan untuk berhenti berlangganan. Berikut adalah kesimpulan utama yang dirumuskan berdasarkan integrasi seluruh temuan.

1. **Dataset telah dipersiapkan dengan kualitas tinggi sebagai fondasi analisis yang andal.** Proses preprocessing menghasilkan dataset bersih (telecom_clean.csv) dengan 1.200 baris dan 42 kolom tanpa missing values. Tahapan feature engineering menghasilkan fitur-fitur baru yang informatif seperti tenure_months, financial_risk, dan bill_to_income_ratio, yang terbukti relevan terhadap perilaku churn.
2. **Segmentasi berbasis K-Means mengidentifikasi akar masalah wasted value secara kuantitatif.** Metode K-Means Clustering menghasilkan segmentasi yang lebih objektif dibandingkan pendekatan kuadran manual. Segmen 1 (High-Paying Victims) dengan churn rate 57% dan tagihan anomali (14.950) membuktikan bahwa ketidaksesuaian harga-nilai adalah pemicu churn paling kritis. Sebaliknya, Segmen 3 (Digital Native) dengan churn rate terendah (29%) membuktikan bahwa kesesuaian paket dengan kebutuhan nyata adalah fondasi loyalitas yang paling efektif.
3. **Frekuensi keluhan dan jenis kontrak terbukti menjadi prediktor churn terukur yang dapat dioperasionalkan.** Notebook B yang menggunakan subset df_churn yang metodologis tepat, menghasilkan gambaran pain points yang jauh lebih akurat. Support tickets terbukti sebagai prediktor churn paling konsisten, dengan pelanggan churn mengajukan tiket hampir tiga kali lebih sering. Tujuh puluh persen pelanggan churn berasal dari kontrak Monthly, konsisten di seluruh 11 kota menjadikannya target intervensi terluas. Jaringan/Sinyal sebagai pain point utama (42%) dan fenomena happy leaver (29%) memberikan nuansa penting dalam merancang strategi retensi yang komprehensif.
4. **Tekanan finansial bersifat universal dan terkonsentrasi secara geografis.** Analisis sensitivitas finansial mengonfirmasi bahwa beban tagihan yang tinggi di tengah inflasi 11,7% menciptakan sensitivitas harga yang merata di seluruh kelompok usia dan pendidikan. Tidak ditemukan perbedaan signifikan pada bill_to_income_ratio antarkelompok demografis, mengimplikasikan bahwa strategi retensi berbasis demografi tidak akan optimal. Sebaliknya, strategi berbasis geografi dengan fokus pada Karachi, Lahore, dan Faisalabad akan jauh lebih cost-effective.
5. **Ketiga dimensi analisis beroperasi secara sinergis dan menciptakan efek berlipat terhadap risiko churn.** Pelanggan yang mengalami wasted value (A), memiliki riwayat keluhan tinggi dan kontrak bulanan (B), serta menanggung beban finansial berat di kota-kota besar (C) merupakan kelompok dengan probabilitas churn tertinggi

yang memerlukan intervensi retensi paling prioritas. Pemahaman efek berlipat ini memungkinkan perusahaan untuk memprioritaskan sumber daya retensi secara lebih tepat sasaran.

5.2 Saran

Berdasarkan temuan dan kesimpulan yang telah disajikan, berikut disampaikan saran untuk pengembangan proyek lebih lanjut maupun untuk implementasi bisnis oleh perusahaan telekomunikasi.

5.2.1 Saran untuk Pengembangan Proyek

1. **Pembangunan model prediksi churn berbasis machine learning.** Dataset `telecom_clean.csv` yang dihasilkan dari proyek ini merupakan fondasi yang siap pakai untuk pemodelan prediktif. Algoritma seperti Random Forest, Gradient Boosting (XGBoost/LightGBM), atau Logistic Regression dapat diuji dan dibandingkan performanya. Fitur-fitur yang telah terbukti relevan dari EDA khususnya `financial_risk`, `tenure_months`, `support_tickets_capped`, `contract_type_encoded`, dan `bill_to_income_ratio` diharapkan menjadi kontributor prediktif yang signifikan.
2. **Operasionalisasi Early Warning System secara real-time.** Berdasarkan temuan Notebook B, sistem skoring risiko churn berbasis ambang batas tiket keluhan dapat dikembangkan dan diintegrasikan langsung ke dalam sistem CRM perusahaan sehingga intervensi retensi dapat dilakukan secara otomatis tanpa bergantung pada pemeriksaan manual.
3. **Perluasan analisis dengan data temporal.** Dataset saat ini bersifat cross-sectional (snapshot). Perluasan analisis dengan memasukkan data longitudinal (time-series) akan memungkinkan identifikasi pola churn berdasarkan musim, tren penggunaan bulanan, atau perubahan perilaku pelanggan setelah setiap interaksi layanan pelanggan.
4. **Perbaikan proses ekstraksi fitur teks Count Vectorizer.** Notebook B mengidentifikasi bahwa variabel `count_billing`, `count_happy`, dan `count_satisfied` bernilai nol pada seluruh observasi, mengindikasikan potensi masalah pada proses keyword matching di Notebook D. Peninjauan ulang dan perbaikan proses Count Vectorizer akan menghasilkan fitur teks yang lebih representatif untuk analisis sentimen lanjutan.
5. **Analisis teks lanjutan menggunakan Natural Language Processing (NLP).** Kolom `customer_feedback` menyimpan potensi informasi yang belum sepenuhnya tergali melalui pendekatan keyword matching. Penerapan teknik NLP yang lebih canggih seperti sentiment analysis berbasis transformer model atau topic modeling (LDA) akan mengekstraksi nuansa keluhan yang lebih granular dan spesifik.

5.2.2 Saran untuk Perusahaan Telekomunikasi

1. **Segera implementasikan Early Warning System berbasis tiket keluhan sebagai prioritas tertinggi.** Sistem ini tidak memerlukan investasi infrastruktur besar namun dapat memberikan dampak retensi yang langsung terukur karena memanfaatkan data operasional yang sudah tersedia. Fokuskan tim retensi pada pelanggan yang mengajukan tiket keluhan kedua atau lebih dalam satu periode.
2. **Lakukan audit menyeluruh terhadap portofolio paket layanan.** Temuan Segmen 1 K-Means (tagihan 3x lipat dengan pemakaian rata-rata) mengindikasikan adanya masalah struktural dalam desain paket atau proses penagihan. Audit harus mengidentifikasi mengapa pelanggan dengan pemakaian biasa dapat terkena tagihan sedemikian tinggi dan memperbaiki struktur harga agar lebih transparan dan proporsional.
3. **Alokasikan anggaran retensi secara asimetris berbasis geografi dan segmentasi K-Means.** Berikan porsi lebih besar kepada wilayah Lahore, Gujranwala, Peshawar, Karachi, dan Faisalabad yang secara konsisten menunjukkan indikator risiko tertinggi dari berbagai dimensi analisis. Fokuskan pula pada Segmen 1 K-Means yang memiliki churn rate tertinggi (57%) namun jumlahnya lebih terbatas sehingga intervensi targeted akan lebih efisien.
4. **Kembangkan program insentif kontrak jangka panjang yang kompetitif.** Perbedaan churn rate yang sangat drastis antara kontrak Monthly (70% dari churn) dan kontrak tahunan merepresentasikan peluang retensi yang sangat besar. Program migrasi yang menawarkan nilai nyata (bukan hanya diskon kecil) — seperti kuota tambahan, prioritas jaringan, atau akses layanan premium — akan secara efektif mengurangi porsi pelanggan yang rentan keluar.
5. **Tambahkan exit survey sebagai standar prosedur pembatalan layanan.** Fenomena happy leaver (29% churn) menunjukkan bahwa data yang tersedia saat ini belum cukup untuk memahami seluruh alasan churn. Exit survey yang terstandarisasi akan menghasilkan data berharga mengenai faktor kompetitor, perubahan kebutuhan, atau ketidakpuasan yang tidak disampaikan melalui saluran keluhan resmi, sehingga strategi retensi dapat disempurnakan secara berkelanjutan.

DAFTAR PUSTAKA

- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., Del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- Keramati, A., Jafari-Marandi, R., Aliannejadi, M., Ahmadian, I., Mozaffari, M., & Abbasi, U. (2014). Improved churn prediction in telecommunication industry using data mining techniques. *Applied Soft Computing*, 24, 994–1012. <https://doi.org/10.1016/j.asoc.2014.08.041>
- Khan, Y., Shafiq, S., Naeem, A., Ahmed, S., Safwan, N., & Hussain, S. (2019). Customers Churn Prediction using Artificial Neural Networks (ANN) in Telecom Industry. *International Journal of Advanced Computer Science and Applications*, 10(9). <https://doi.org/10.14569/IJACSA.2019.0100918>
- Kotler, P., & Keller, K. L. (2016). *Marketing Management* (15th ed.). Pearson.
- Kotu, V., & Deshpande, B. (2019). *Data science: Concepts and practice* (2nd ed.). Morgan Kaufmann.
- Latief, I. M., Subekti, A., & Gata, W. (2021). PREDIKSI TINGKAT PELANGGAN CHURN PADA PERUSAHAAN TELEKOMUNIKASI DENGAN ALGORITMA ADABOOST. *Jurnal Informatika*, 21(1), 34–43. <https://doi.org/10.30873/ji.v21i1.2867>
- McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter* (3rd ed.). O'Reilly Media.
- Mittal, V., Han, K., Frennea, C., Blut, M., Shaik, M., Bosukonda, N., & Sridhar, S. (2023). Customer satisfaction, loyalty behaviors, and firm financial performance: What 40 years of research tells us. *Marketing Letters*, 34(2), 171–187. <https://doi.org/10.1007/s11002-023-09671-w>
- Negassa, G. J., & Japee, G. P. (2023). The Effect of Bonding, Responsiveness and Communication on Customer Retention: The Mediating Role of Customer Satisfaction. *Journal of Relationship Marketing*. <https://doi.org/10.1080/15332667.2023.2191111>
- NumPy Developers. (2025). NumPy documentation. <https://numpy.org/doc/>
- Pakistan Bureau of Statistics. (2026). *Monthly Review on Price Indices: May 2026*. Government of Pakistan.
- Pandas Development Team. (2025). Pandas documentation. <https://pandas.pydata.org/docs/>

- Provost, F., & Fawcett, T. (2013). *Data science for business: What you need to know about data mining and data-analytic thinking*. O'Reilly Media.
- Python Software Foundation. (2024). Python documentation. <https://docs.python.org/3/>
- Ratnawati, D. E. (2020). *Preprocessing data* [Materi perkuliahan]. Fakultas Ilmu Komputer, Universitas Brawijaya.
- Ratnawati, D. E. (2024). *Eksplorasi data dan visualisasi data* [Materi perkuliahan]. Fakultas Ilmu Komputer, Universitas Brawijaya.
- Ratnawati, D. E. (2025). *Eksplorasi data dan visualisasi data* [Materi perkuliahan]. Fakultas Ilmu Komputer, Universitas Brawijaya.
- Ribeiro, H., Barbosa, B., Moreira, A. C., & Rodrigues, R. G. (2024). Determinants of churn in telecommunication services: A systematic literature review. *Management Review Quarterly*, 74, 1327–1364. <https://doi.org/10.1007/s11301-023-00335-7>
- Rosário, A., & Casaca, J. A. (2023). Relationship Marketing and Customer Retention: A Systematic Literature Review. *Studies in Business and Economics*.
- Seaborn Development Team. (2025). Seaborn documentation. <https://seaborn.pydata.org/>
- Van Rossum, G., & Drake, F. L. (2021). *The Python language reference* (Version 3.10). Python Software Foundation. <https://docs.python.org/3/reference/>
- Waskom, M. L. (2021). Seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021. <https://doi.org/10.21105/joss.03021>
- Yum, K., & Yoo, B. (2023). The Impact of Service Quality on Customer Loyalty through Customer Satisfaction in Mobile Social Media. *Sustainability*, 15(14), 11211. <https://doi.org/10.3390/su151411214>

LAMPIRAN

Notebook :  NOTEBOOK_Telecom_Churn_Rate - Kelompok 2

Github : [Link GitHub](#)

Canva : [Link Canva](#)